


Unit 03: Pandas 資料處理與分析


Section 5 - 資料清理與處理



建構可靠的化工數據分析基礎

數據雜訊的代價：Garbage In, Garbage Out


❗ 缺失值 (Missing Values)



```
data_value = stream.read(); // 缺失  
process_result = data_value * 5.0; // 錯誤
```

導致運算錯誤傳播 (NaN propagation)。


❗ 資料型態錯誤 (Wrong Types)



```
input_value = "100"; // 字串  
model_input = float(input_value); // 錯誤  
predict(model_input);
```

導致數學模型崩潰 (Model Crash)。

❗ 重複值 (Duplicates)




```
data = [100, 150, 100, 200, 150];  
cleaned_data = unique(data);  
count_stats(data); // 錯誤統計
```

導致統計結果偏差 (Statistical Bias)。

Section 5 總覽：資料提煉製程

SYSTEM STATUS: OPERATIONAL
DATE: 2024.05.23 REV: 1.3



5.1 偵測缺失值：診斷數據完整性

SOP：診斷指令

檢查缺失值狀態

```
df.info()
```


統計每欄位的缺失值數量

```
missing_count = df.isnull().sum()
```

Time	Temp_C	Pressure_Bar
08:00	85.2	1.2
08:05	NaN	1.1
08:10	86.1	None
08:15	85.9	1.3

isnull() 與 isna() 是偵測數據空洞的探針。

5.1 處理策略 A：移除 (Filtration)




```
# 移除包含任何 NaN 的列 (Row)  
clean_df = df.dropna()
```

```
# 僅移除特定欄位 (如：反應溫度) 缺失的列  
clean_df = df.dropna(subset=[ 'Reactor_Temp' ])
```



注意：若數據缺失比例過高，移除操作可能導致樣本不足 (Data Loss Risk)。


5.1 處理策略 B：填補 (Imputation)



固定值填補 (Fill with Value)

`df.fillna(0)` 或 `df.fillna(df.mean())`


用於建立統計基準。




向前填補 (Forward Fill)

`df.fillna(method='ffill')`

化工感測器應用 (Sensor Application):
使用 ffill 延續上一次的有效讀數，
模擬連續監控。



5.2 處理重複值：訊號去噪



情境：感測器在同一時間戳記記錄了兩次數據。

檢查重複列


```
duplicates = df.duplicated()
```

移除重複列，保留第一筆出現的資料


```
df_unique = df.drop_duplicates(keep='first')
```

5.3 資料型態轉換：標準化

String




Numeric
(Float)



```
# 將 'Pressure' 欄位轉換為浮點數  
df['Pressure'] = df['Pressure'].astype(float)
```

```
# 強制轉換，遇錯則設為 NaN (Coerce errors)  
df['Level'] = pd.to_numeric(df['Level'], errors='coerce')
```

5.4 字串處理：文本解析




```
# 去除單位字串 (如 '85 C' -> '85')
df['Temp'] = df['Temp'].str.replace(' C', '')

# 去除前後空白
df['Batch_ID'] = df['Batch_ID'].str.strip()

# 轉換後記得變更型態
df['Temp'] = df['Temp'].astype(float)
```

綜合演練：反應器數據清理流程




常見陷阱與安全規範




SettingWithCopyWarning

問題：直接修改 DataFrame 切片。
修正：使用 `.loc` 或 `.copy()`。




Chained Assignment

問題：`df[condition]['col'] = 0` 寫法不明確。
修正：使用明確賦值。




驗證 (Verification)

規則：清理後務必執行 `df.info()` 確認結果。



資料清理標準作業程序 (SOP)



Unit 04 預告：資料視覺化 (Data Visualization)