



Unit 03: Pandas 資料處理與分析 - Part 7

資料合併與分組 (Data Merging & Grouping)





將零散的數據流，組裝成有價值的決策資訊

數位單元操作：資料處理工具箱



就像化工廠中的混合器與分離器，Pandas 提供了四種核心工具來重組與聚合數據流。


資料串接 (Concatenation)：物理性的堆疊



⚠ Key Takeaway: `pd.concat` 不涉及邏輯判斷，僅是將兩個 DataFrame 依照索引物理性地拼接在一起。


資料合併 (Merge)：關聯式邏輯連接

類似 SQL 的 JOIN 操作，必須依賴共同的「鍵 (Key)」來對齊資料。




合併模式 (Merge Types)：決定資料的去留

Inner Join
(交集)




僅保留兩邊都有的時間點




Outer Join
(聯集)

保留所有數據，缺失處填補 NaN

Left Join



以左表為主 (Keep Left)




Right Join

以右表為主 (Keep Right)


⚠ 警示：化工數據建議優先考慮 Outer Join 以保留完整時間軸，避免因 Inner Join 造成數據遺失。

決策矩陣：該用 Merge 還是 Concat？



Concat: 物理拼接 (Physical Splicing) | Merge: 邏輯關聯 (Logical Relational Join)

分組運算 (GroupBy) : Split-Apply-Combine 策略



```
</> df.groupby('Catalyst')['Yield'].mean()
```

聚合函數 (Aggregation)：反應器內的運算

Specification Sheet

函數 (Function)	說明 (Description)	應用範例 (Example)
 mean()	計算平均值	平均反應溫度
Σ sum()	加總	總產量計算
 max() / min()	極值	峰值壓力監測
 std()	標準差	製程穩定性分析
 count()	計數	異常警報次數


Pro Tip



進階技巧:
使用 `.agg(['mean', 'std'])` 可以同時計算多種統計量，一次獲得製程的中心趨勢與變異程度。

多重鍵分組 (Multi-Key Grouping)

同時依據多個維度進行切片分析



```
# 依照 'Date' 和 'Reactor_ID' 兩層分組  
df.groupby(['Date', 'Reactor_ID'])  
  ['Pressure'].max()
```


透過多層索引 (Multiindex)，
我們可以比較不同日期下，
各反應器器的效能差異。

透視表 (Pivot Table)：數據報表化

從機器讀取格式 (Long) 轉換為人類閱讀格式 (Wide)

Raw Log Data

Roboto Mono		
Date	Reactor	Efficiency
2025-01-01	R-101	85.5
2025-01-01	R-102	90.2
2025-01-02	R-101	87.1
2025-01-02	R-102	89.8
2025-01-03	R-101	86.0



Manager Report

Roboto Mono		
	Reactor	
	R-101	R-102
2025-01-01	85.5	90.2
2025-01-02	87.1	89.8
2025-01-03	86.0	---


```
pd.pivot_table(df,
values='Efficiency',
index='Date',
columns='Reactor_ID',
aggfunc='mean')
```

實戰案例：催化劑效能分析

目標：找出不同催化劑的最佳操作溫度區間




原始實驗數據
(Raw Data)



Roboto Mono


```
Rows: Temp |  
Cols: Catalyst |  
Values: Conversion
```



Optimal
Operating
Window
(最佳操作區間)

透過 Pivot Table 與熱圖 (Heatmap) 結合，
工程師可以一眼看出哪種催化劑在什麼溫度
下表現最好。

最佳實踐與安全檢查 (Checklist)



- ✓ **核查維度 (Check Dimensions)**
合併後是否有意外的列數增加 (Duplicates) ?
- ✓ **缺失值處理 (Handle NaNs)**
Outer Join 後產生的 NaN 務必使用 ``fillna()`` 處理。
- ✓ **索引對齊 (Index Alignment)**
``concat`` 時注意 axis 設定，避免維度混淆。
- ✓ **記憶體管理**
大型數據集操作前，建議先篩選必要欄位。

好的資料結構是高效分析的基礎

(Good data structure is the foundation of efficient analysis).

下一步：數據視覺化

Unit 03 完成：
資料管線連接
與聚合



Unit 04 預告：
Matplotlib 與
Seaborn 視覺化

→ 開始練習：開啟 Unit03_Pandas_Part7.ipynb