


Unit 03 Pandas 總結與最佳實踐

打造穩健的化工數據處理核心



Course: AI在化工上之應用


Instructor: 莊曜禎 助理教授



Date: 2026-01-28

Dept: 逢甲大學 化工系


系統盤點：Pandas 核心架構圖




結構與定位：資料儲存與精準索引

結構可視化 (Structure Visualization)

Series (一維標籤陣列)



DataFrame (二維標籤表格)



定位系統比較 (Indexing Systems)

System A: .loc [Label]




依據「標籤」定位
(Label-based)

```
df.loc['2023-01-01',  
      'Temperature']
```

直觀，適合業務邏輯選取

System B: .iloc [Integer]

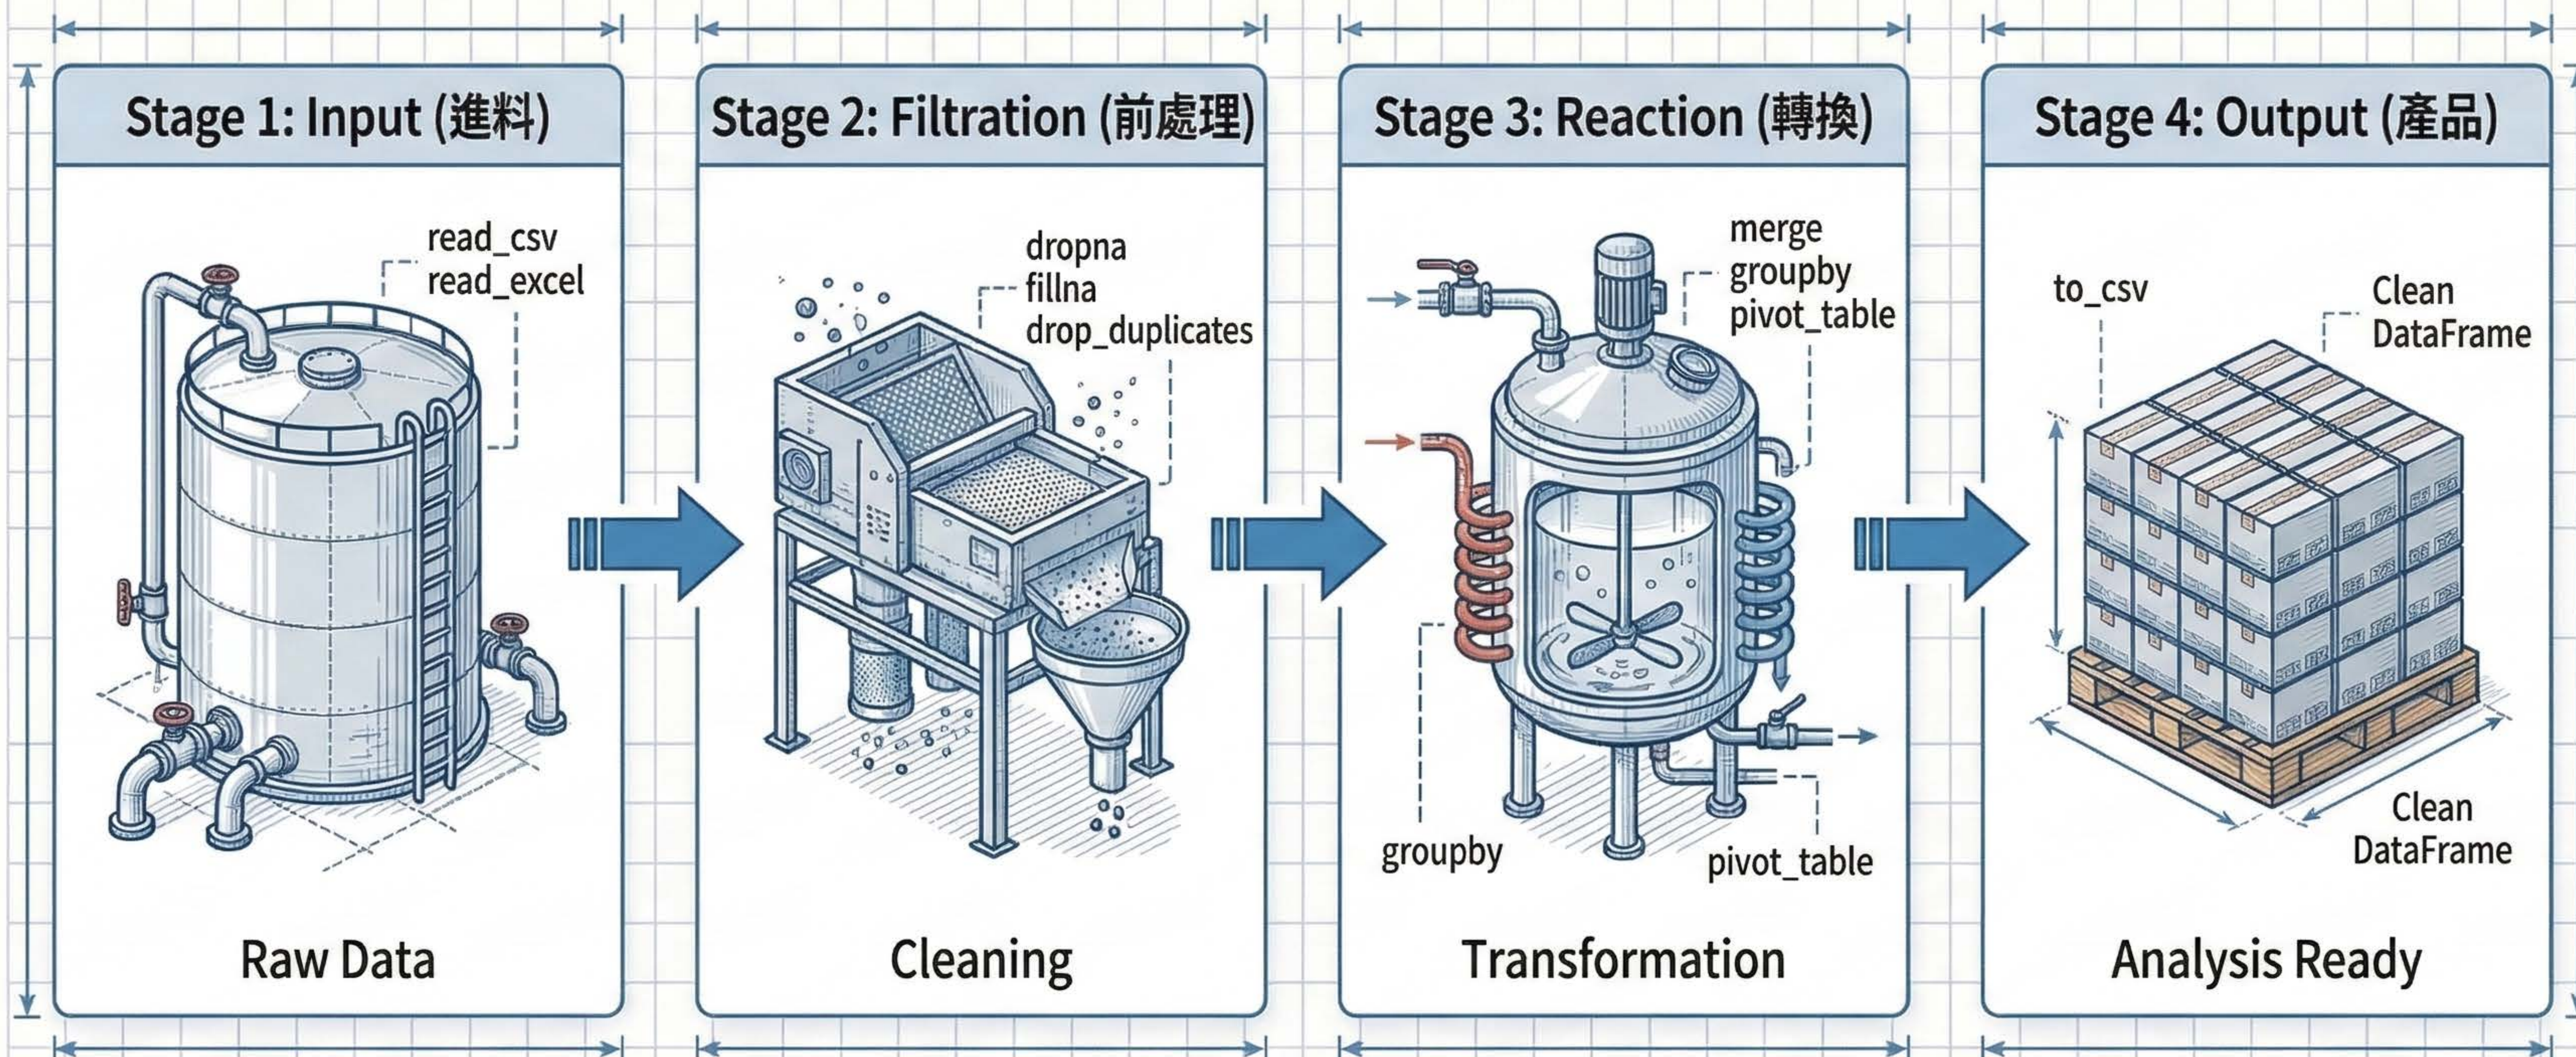


依據「整數位置」定位
(Position-based)

```
df.iloc[0, 1]
```

精確，適合迴圈或固定位置選取

資料流程序：從原始數據到分析就緒



良好的資料流設計能確保分析結果的可再現性 (Reproducibility) 與準確性。

安全操作規範：常見陷阱警示



DANGER / WARNING



視圖與副本 (Views vs. Copies)

`SettingWithCopyWarning` – 賦值對象不明確。



索引未對齊 (Index Misalignment)

運算結果產生大量 NaN 空值。



記憶體溢出 (Memory Overflow)

處理大型數據集時系統崩潰。



定位混淆 (Location Confusion)

混用 loc (標籤) 與 iloc (位置)。



隱形缺失值 (Hidden NaNs)

忽略 NaN 導致統計結果偏差。

陷阱詳解 I：SettingWithCopyWarning

問題：在 DataFrame 的切片 (Slice) 上直接賦值，導致 Pandas 無法確定是要修改原始資料還是副本。

❌ 危險操作 (Chained Indexing)


錯誤寫法

```
df[df['T'] > 100]['Status'] = 'High'
```

警告：SettingWithCopyWarning

A value is trying to be set on a copy of a slice...

Chained Indexing



✅ 安全規範 (Use .loc)


解法 1：使用 .loc (推薦)

```
df.loc[df['T'] > 100, 'Status'] = 'High'
```

解法 2：明確建立副本

```
df_high = df[df['T'] > 100].copy()
```


```
df_high['Status'] = 'High'
```



Rule: Chained Indexing (連鎖索引) 是危險操作，請始終使用 `.loc` 進行精確賦值。

陷阱詳解 II：索引對齊與定位

索引對齊 (Index Alignment)




Pandas 自動依據索引對齊。若索引不匹配，運算結果將產生 NaN。



解法：運算前檢查索引，或使用
`reset\_index()` 重置索引。

定位精確度 (Selection Precision)



混用標籤 (Label) 與位置 (Integer) 容易導致選錯資料，特別是當索引本身就是整數時。



Key Principle (關鍵原則)：
Explicit is better than Implicit (明確優於隱晦)。



- ✓ 明確區分 `loc` (標籤)
- ✓ 明確區分 `iloc` (位置)

陷阱詳解 III：記憶體管理與缺失值

記憶體溢出 (Memory Overflow)


➤ 化工時間序列數據往往龐大，容易耗盡記憶體。

Chunking



使用 `chunksize` 分批讀取
(Batch Processing)


Strategies



Dtype Optimization



降轉型別 (`float64` -> `float32`)



隱形缺失值 (Hidden NaNs)

NaN 會傳播 (Propagate)，導致後續計算全部失效。
Protocol



檢測
`df.isnull().sum()`


處理 `dropna()`
(移除)




處理 `dropna()`
(移除)



處理 `fillna()`
(填補)



運維最佳實踐：程式碼的 5S 管理



“Code is read much more often than it is written.”
(程式碼被閱讀的次數遠多於被撰寫的次數)


延伸學習路徑：擴充您的工具箱

官方文檔
(Documentation)

經典書籍
(Books)

實戰演練
(Practice)

進階主題
(Advanced)



最權威的參考手冊

Wes McKinney 親撰

Kaggle Datasets &
化工製程數據
(Process Data)

多層索引 (MultiIndex)
自訂函數 (Apply)
效能優化

結語：您的數據已準備就緒

