Unit 06：主成分分析 (Principal Component Analysis, PCA)

DOC // U06-COVER-01 | SCALE: 1:1 | REV: 2026.10

PART 2 · UNIT 06 | UNSUPERVISED LEARNING

主成分分析 (PCA)

線性降維與化工製程監控實戰

> 如何將上百個高度共線性的化工感測器訊號，濃縮為少數獨立的**物理主成分 (Principal Components)**，並建立工業級 T^2 + SPE 雙軌製程監控儀表板？

本單元四大核心學習支柱

CURRICULUM ROADMAP

01 · 幾何與數學引擎
變異數最大化、正交投影、特徵分解與 SVD

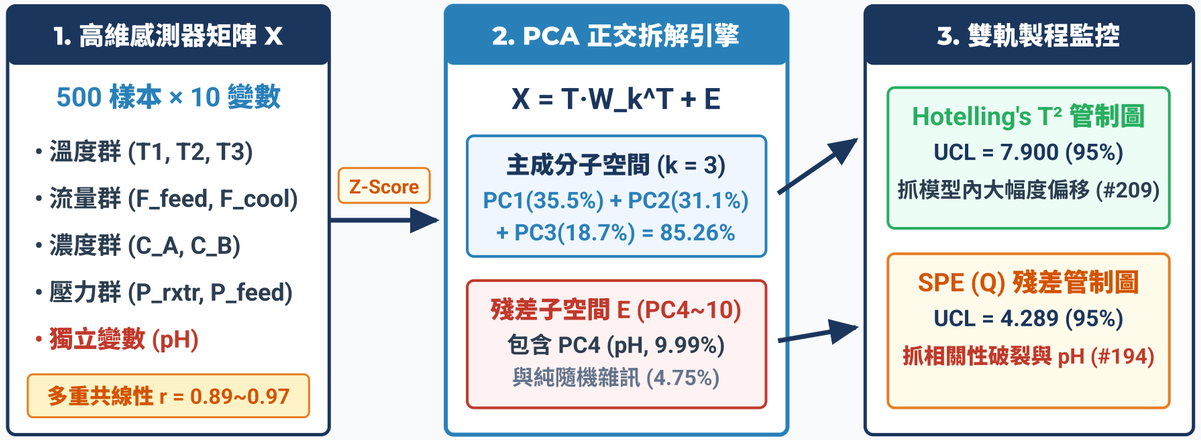
02 · 尺度標準化鐵律
消除量綱主導效應、嚴防訓練/測試資料洩漏

03 · 四大視覺化診斷圖
Scree Plot、Loadings、Score Plot 與 Biplot

04 · 工業雙軌製程監控
Hotelling's T^2、SPE (Q) 管制圖與貢獻圖診斷

SYSTEM ARCHITECTURE // 化工大數據降維與監控藍圖

BLUEPRINT SCHEMATIC



ENGINEERING SPECIFICATION // TITLE BLOCK

DWG NO: CHEME-3590-U06-PCA

COURSE NAME **電腦在化工上之應用 (ChemE 3590)**	INSTITUTION & LAB **逢甲大學化工系 · 智慧程序系統工程實驗室**
INSTRUCTOR **莊曜禎 助理教授 (Prof. Yao-Chen Chuang)**	CASE BENCHMARK **CSTR (N = 500, p = 10, k = 3, seed = 42)**

化工廠的「資訊過載」危機：高維感測器與維度災難

DOC // U06-MOTIV-02 | SCALE: 1:1 | REV: 2026.10

為什麼化工廠需要「降維」？

MOTIVATION

- **現代 DCS / 資料歷史庫的「資訊過載」**：一座中型石化廠或反應程序動輒安裝 **500 ~ 5,000 支感測器**（溫度、壓力、流量、液位、濃度、pH），每秒鐘產生龐大的高維度數據矩陣 X。
- **維度災難 (Curse of Dimensionality)**：當特徵維度 p 過高時，歐氏距離失去鑑別力，監督式回歸與分類模型極易陷入**嚴重過擬合 (Overfitting)**。
- **人眼無法同時監看上百張單變數管制圖**：若對 100 個變數各自設 95% 單變數警報，即使製程完全正常，整體誤報率也會高達 $1 - 0.95^{100} = 99.4\%$（警報洪水 Alarm Flooding）！

核心洞見： 雖然表面上有 p 個感測器，但真正驅動製程變化的**獨立物理自由度 (Latent Driving Forces)** 通常只有少數 k 個（例如 $k = 2 \sim 5$）！

高維感測器糾纏 vs. PCA 正交潛在變數解耦

DIMENSIONALITY REDUCTION

原始感測器空間 (p = 10 維)

⚠️ 變數彼此高度糾纏、大量重複資訊

- Reactor / Jacket / Product Temp
  熱平衡強烈耦合 (r = 0.89 ~ 0.97)
- Feed_Flow / Coolant_Flow / P_feed
  流體力學與控制連動 (r = 0.80 ~ 0.94)
- Reactant_A_Conc / Reactant_B_Conc
  化學計量同步消耗 (r = 0.92)
- pH (酸鹼度感測器)
  唯一獨立運作變數 (|r| < 0.05)

PCA 旋轉
T = X · W_k

主成分與殘差空間 (正交解耦)

✓ 彼此完全正交 (r = 0.00)，物理意義清晰

- PC1 (35.50% 變異)
  反應器整體熱力學狀態軸 (T & P)
- PC2 (31.10% 變異)
  流體力學與冷卻負荷控制軸 (F)
- PC3 (18.66% 變異)
  進料反應物濃度主導軸 (C_A, C_B)
- 殘差空間 E (含 PC4: pH 9.99%)
  由 SPE (Q) 管制圖負責嚴密監控！

化工數據的本質：物理定律約束與四大應用場景

DOC // U06-APPL-03 | SCALE: 1:1 | REV: 2026.10

物理定律約束與多重共線性

COLLINEARITY

- **為什麼化工數據必定高度共線？**
  感測器並非獨立隨機跳動，而是同時受到**質量守恆、能量守恆、熱力學相平衡與控制迴路**的嚴格約束。
- **典型化工共線性機制：**
  - 放熱反應升溫 → 夾套與出料溫度同步上升
  - 密閉反應器升溫 → 飽和蒸氣壓與總壓同步上升
  - 進料流量提高 → 控制器自動調大冷卻水流量
- **本單元要回答的三個核心問題：**
  1. 如何將共線變數壓縮成少數正交主成分？
  2. 如何從權重 (Loadings) 解讀主成分的物理意義？
  3. 如何用 T^2 與 SPE 進行異常偵測與根因診斷？

PCA 在化學工程領域的四大核心應用場景

APPLICATIONS

應用領域	化工實務問題與痛點	PCA 解決方案與工程效益
1. 多變數製程監控 (MSPC / 異常偵測)	**單變數管制圖 (Shewhart) 忽略變數間相關性，無法察覺「溫度高但壓力卻偏低」的耦合異常。**	**建立 Hotelling's T^2 + SPE (Q) 雙張管制圖，搭配貢獻圖直接鎖定異常感測器。**
2. 軟感測器建模 (PCR 主成分迴歸)	以 50 個共線感測器直接做最小平方法 (OLS) 預測產品純度，迴歸係數會因 X^TX 接近奇異而劇烈震盪。	先轉為互不相關的得分 T 再建立迴歸模型 (PCR)，徹底消除共線性並濾除高頻雜訊。
3. 光譜分析與感測 (NIR / Raman / FTIR)	近紅外或拉曼光譜動輒 1,000+ 個波長通道，相鄰波長吸光度極度重疊 ($r > 0.99$)。	將上千波長壓縮至 3 ~ 5 個代表化學官能基的主成分，大幅加速即時線上成分推估。
4. 操作模式視覺化 (製程歷史探索)	工程師無法在 10 維空間觀察催化劑老化、操作班別切換或不同進料批次的聚落軌跡。	透過 2D **得分圖 (Score Plot)** 與 **雙標圖 (Biplot)**，一眼看穿正常聚落與離群樣本。

PCA 的核心哲學 (1)：變異數最大化與正交軸旋轉

DOC // U06-GEOM-04 | SCALE: 1:1 | REV: 2026.10

視角一：變異數最大化 = 資訊量最大化

MAX VARIANCE

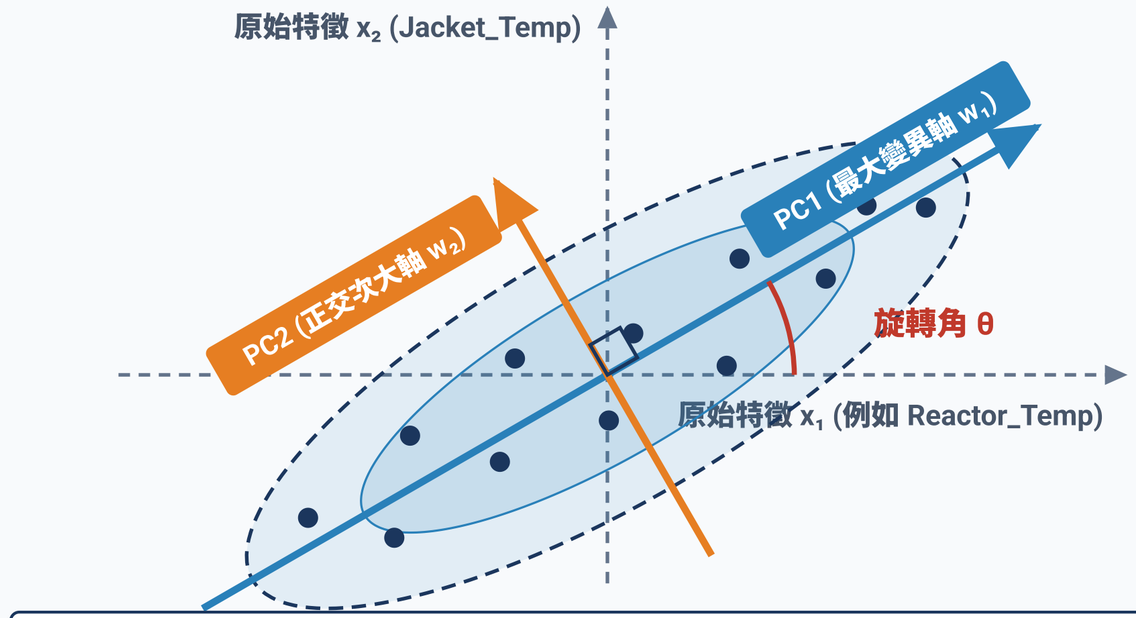
- **在訊號處理中，「變異數 (Variance)」代表資訊**：若某個方向上所有樣本的投影值都一模一樣（變異數為 0），代表該方向完全無法區分不同樣本的狀態。
- **第一主成分 (PC1)**：尋找單位法向量 w_1（滿足 $||w_1||_2 = 1$），使得所有樣本投影後的**得分變異數達到最大**。
- **第二主成分 (PC2)**：在**嚴格正交於** PC1（即 $w_1^T w_2 = 0$）的所有方向中，尋找能解釋最多剩餘變異數的方向。

$$\max_{||w_1||=1} \mathrm{Var}(X w_1) = w_1^T C w_1 = \lambda_1$$

幾何本質： PCA 並沒有扭曲數據點之間的歐氏距離，它只是將原始座標軸 (x_1, x_2) **剛體旋轉 (Rigid Rotation)** 對齊資料橢圓雲的主軸與次軸！

FIG 3A // 座標軸剛體旋轉：對齊資料橢圓雲之最大變異方向

GEOMETRIC ROTATION



正交條件：$w_1^T w_2 = 0$ ⇒ 投影後得分 $Cor(t_1, t_2) = 0$ （徹底消除多重共線性！）

總變異數守恆：$Var(x_1) + Var(x_2) = \lambda_1$ (PC1 解釋變異) + λ_2 (PC2 解釋變異)

PCA 的核心哲學 (2)：最小化正交重建誤差 vs. 線性迴歸 (OLS)

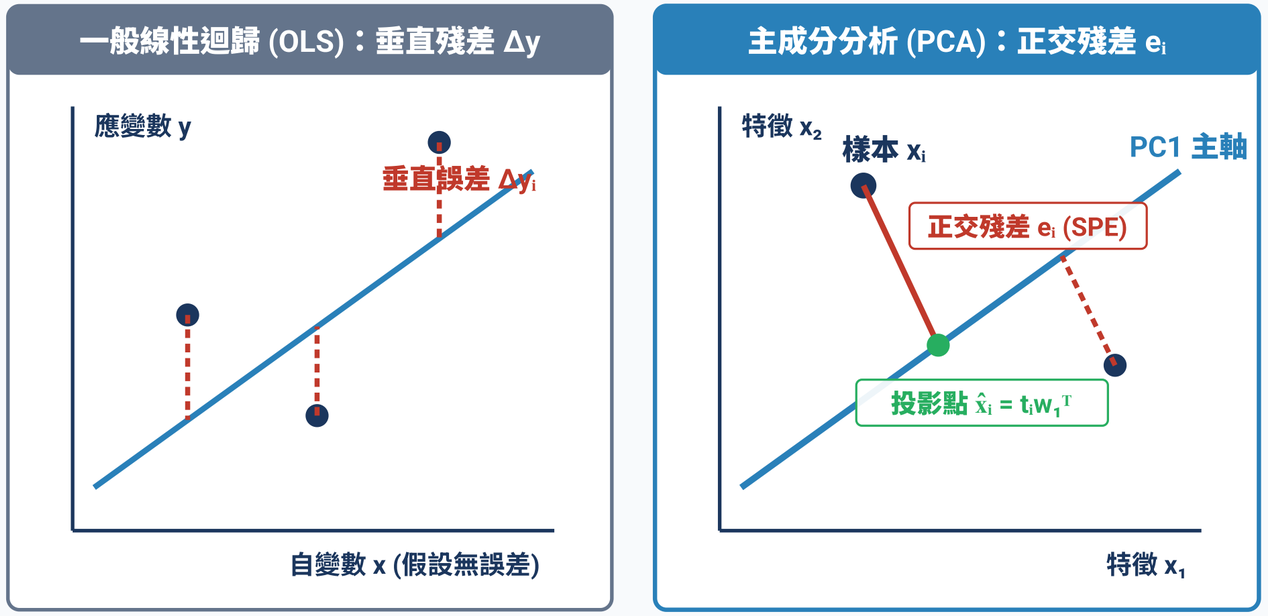
DOC // U06-GEOM-05 | SCALE: 1:1 | REV: 2026.10

視角二：最小化正交投影重建誤差 MIN RECONSTRUCTION ERROR

- **畢氏定理 (Pythagorean Theorem) 的完美等價：**
  每一個中心化樣本點 x_i 到原點的距離平方（總長度）是固定的：
  $||x_i||^2 = ||\hat{x}_i||^2$ (投影得分平方) + $||e_i||^2$ (正交殘差平方)。
- 因此，**最大化投影變異數** $\sum||\hat{x}_i||^2$，在數學上百分之百等價於**最小化正交重建誤差平方和** $\sum||e_i||^2$！
- **千萬別把 PCA 與線性迴歸 (OLS) 搞混！**
  • **OLS 迴歸**：假設 x 無誤差，最小化**垂直方向 (y 軸)** 誤差。
  • **PCA 降維**：所有變數地位對等，最小化**垂直於主軸的正交距離 (Orthogonal Distance)**，這正是 **SPE (Q) 統計量**的幾何定義！

$$\mathrm{SPE}_i = ||e_i||^2 = ||x_i - \hat{x}_i||^2$$

FIG 3B // PCA 正交投影殘差 (Orthogonal) vs. OLS 垂直殘差 (Vertical) PCA VS. OLS



關鍵差異：化工感測器 x_1 與 x_2 皆含有量測雜訊，且無「自變數/應變數」之分
⇒ PCA 最小化正交距離 $||e_i||^2$ (Total Least Squares)，完美分離「主成分子空間 $\hat{x}_i$」與「殘差子空間 e_i」！

預處理鐵律 (1)：尺度主導效應與 Z-Score 標準化

尺度主導效應 (Scale Dominance) 陷阱

CRITICAL RULE

- **為什麼做 PCA 前一定要先做標準化？**
  因為 PCA 是一個「追逐最大變異數」的演算法！若直接對原始單位做 PCA，**數值單位較大的變數會完全綁架第一主成分**。
- **化工實例對比**：
  - 反應器流量 `Feed_Flow`：100 ± 15 L/min（變異數 $\sigma^2 = 225$）
  - 酸鹼度 `pH`：7.0 ± 0.2（變異數 $\sigma^2 = 0.04$）
  - 未標準化時，流量變異數是 pH 的 **5,625 倍**！PCA 會把 99.9% 權重全給流量，徹底無視 pH 與濃度的變化。
- **Z-Score 標準化 (Auto-scaling)**：將每個特徵 j 平移至平均值 0、縮放至標準差 1（單位變異數）：

$$z_{ij} = (x_{ij} - \mu_j) \,/\, \sigma_j \;\Rightarrow\; \mu_z = 0,\;\; \sigma_z^{\,2} = 1$$

未標準化 (Unscaled) vs. Z-Score 標準化後之特徵變異數對比

Z-SCORE SCALING

[X] 錯誤做法：直接對原始物理單位做 PCA (共變異數矩陣被大數值變數壟斷)



✓ 正確做法：先經 StandardScaler 標準化 (每個變數立足點平等，σ² = 1.00)



⇒ 標準化後的共變異數矩陣 C 即等於「皮爾森相關係數矩陣 R」，10 個變數總變異數 = 10.0！

預處理鐵律 (2)：嚴防資料洩漏 (Data Leakage) 與程式實作

DOC // U06-PREP-07 | SCALE: 1:1 | REV: 2026.10

嚴防資料洩漏 (Data Leakage) 鐵律

ANTI-LEAKAGE

- **工業製程監控的黃金基準 (Normal Baseline)：**
  模型訓練階段只能使用「正常操作區間」的歷史數據 X_{train} 來計算平均值 μ_{train}、標準差 σ_{train} 與主成分軸 W_k。
- **線上監控或測試新樣本 X_{new} 時：**
  - **絕對禁止**對新樣本重新呼叫 `fit()` 或 `fit_transform()`！
  - 若將含有異常故障的新數據混入計算平均值與標準差，異常樣本會把基準線拉偏，導致管制圖「掩耳盜鈴」漏報異常！
- **正確的兩階段 API 呼叫準則：**
  - 訓練集：`scaler.fit_transform(X_train)`
  - 測試集 / 線上新數據：`scaler.transform(X_new)`

Scikit-learn 標準化與 PCA 建模標準管線

PYTHON IMPLEMENTATION

```python
from sklearn.preprocessing import StandardScaler
from sklearn.decomposition import PCA

# 1. 訓練階段：僅在正常操作數據 X_train (500×10) 上擬合基準
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)

# 驗證標準化結果：Mean ≈ 0.000000, Std ≈ 1.000000
print(f"Mean: {X_train_scaled.mean(axis=0).round(6)}")
print(f"Std : {X_train_scaled.std(axis=0).round(6)}")

# 2. 建立 PCA 模型並保留前 k = 3 個主成分
pca = PCA(n_components=3, random_state=42)
T_train = pca.fit_transform(X_train_scaled)  # 得分矩陣 (500×3)

# 3. 線上部署階段：新樣本必須沿用訓練集的 μ_train, σ_train, W_k
X_new_scaled = scaler.transform(X_new)          # 僅 transform！
T_new        = pca.transform(X_new_scaled)      # 投影至主成分空間
X_new_recons = pca.inverse_transform(T_new)     # 重建預測值 x̂
```

課堂實作驗證： 在本單元 CSTR 案例中，全部 500 筆樣本皆為常態操作數據作為訓練基準，標準化後每個變數平均皆為 `0.000000`、標準差皆為 `1.000000`，總變異數嚴格等於 `10.0`。

數學引擎 (1)：PCA 演算法四步驟推導與特徵值分解

從拉格朗日乘數法到特徵值問題

MATHEMATICAL PROOF

- **目標函數**：最大化投影後變異數 $w^T C\, w$，同時受限於單位向量約束 $w^T w = 1$。
- **拉格朗日函數 (Lagrangian)**：
  定義 $L(w, \lambda) = w^T C\, w - \lambda(w^T w - 1)$，對 w 偏微分設為零，立即得到經典**特徵值方程**：

$$C\, w_m = \lambda_m\, w_m \quad (\mathrm{m} = 1, 2, \ldots, \mathrm{p})$$

- **物理意義一覽無遺**：
  • 特徵向量 w_m：第 m 主成分的**負荷向量 (Loadings)**，代表旋轉後的新座標軸方向。
  • 特徵值 λ_m：樣本在 w_m 軸上的**投影得分變異數**！特徵值愈大，代表該主成分攜帶的製程資訊量愈豐富。

PCA 演算法核心四步驟藍圖 (Step-by-Step Blueprint)

ALGORITHM STEPS

STEP 01 · 樣本共變異數矩陣

將標準化後的數據矩陣 $X(n \times p)$ 計算對稱半正定共變異數矩陣 $C(p \times p)$：

$$C = 1/(n-1)\; X^T X$$

STEP 02 · 特徵分解與降序排列

求解特徵值與正交特徵向量，並依特徵值由大到小排序，取前 k 個組成 $W_k(p \times k)$：

$$\lambda_1 \geq \lambda_2 \geq \ldots \geq \lambda_p \geq 0$$

STEP 03 · 正交投影計算得分 T

將 n 個樣本線性投影至前 k 個主成分軸，獲得低維度主成分得分矩陣 $T(n \times k)$：

$$T = X\, W_k$$

STEP 04 · 近似重建與殘差矩陣 E

將得分反投影回原空間得重建矩陣 $\hat{X}$，與原數據之差即為殘差矩陣 $E(n \times p)$：

$$\hat{X} = T\, W_k^T, \quad E = X - \hat{X}$$

數學引擎 (2)：子空間矩陣拆解與奇異值分解 (SVD)

為什麼 Scikit-learn 底層採用 SVD？

SVD ENGINE

- **直接算 X^TX 的數值不穩定性：**
  當特徵高度共線或維度極高時，顯式相乘 X^TX 會使條件數平方 ($\kappa(X^TX) = \kappa(X)^2$)，導致浮點數精度流失。
- **奇異值分解 (Singular Value Decomposition, SVD)：**
  直接對標準化資料矩陣 X 進行分解：

$$X = U \Sigma V^T \;\Rightarrow\; \lambda_m = \sigma_m{}^2 / (n-1)$$

- **對應關係與 Scikit-learn 關鍵屬性：**
  - 右奇異向量 V 即為負荷矩陣 W (對應 `pca.components_.T`)
  - 特徵值 λ_m 對應 `pca.explained_variance_`
  - 解釋變異比例 $\lambda_m / \sum \lambda_j$ 對應 `pca.explained_variance_ratio_`

CSTR 實戰數據之正交子空間矩陣拆解藍圖 (N = 500, p = 10, k = 3)

MATRIX ARCHITECTURE

X (500×10) = X̂ (主成分重建子空間 500×10) + E (正交殘差子空間 500×10)



⚠️ **Scikit-learn 維度提醒：pca.components_ 形狀為 (k, p) = (3, 10)，每一列 (Row) 是一個主成分！**
若要以欄位代表主成分建立 DataFrame，務必轉置：pd.DataFrame(pca.components_.T, index=features)

實戰案例：CSTR 反應器模擬數據與常態分布檢驗

CSTR 反應器模擬數據集規格

DATASET SPEC

- **製程背景**：連續攪拌槽式反應器 (CSTR) 放熱反應程序，收集 $N = 500$ **筆正常操作樣本**（`seed = 42`），共監測 $p = 10$ **個製程變數**。
- **無人工注入故障之純淨基準**：全部 500 筆皆作為訓練集 X_{train}，用來建立黃金基準並檢驗 95% 信賴水準下之自然極端波動。
- **建模前必做單變數分布診斷**：
  - 檢查各變數是否近似**高斯常態分布 (Gaussian Bell Curve)**。
  - 因為後續 Hotelling's T^2 的 F 分布控制限，嚴格建立在**主成分得分服從多變數常態分布**的統計假設之上！

診斷結論： 右圖 10 個變數經 Z-Score 標準化後，直方圖皆呈現對稱鐘形分布、集中於 [−3, +3] 區間，無極端偏態或雙峰現象，適合直接執行線性 PCA。

FIG 01 // STANDARDIZED FEATURE DISTRIBUTIONS (10 PROCESS VARIABLES, N = 500) FILE: data_distribution.png

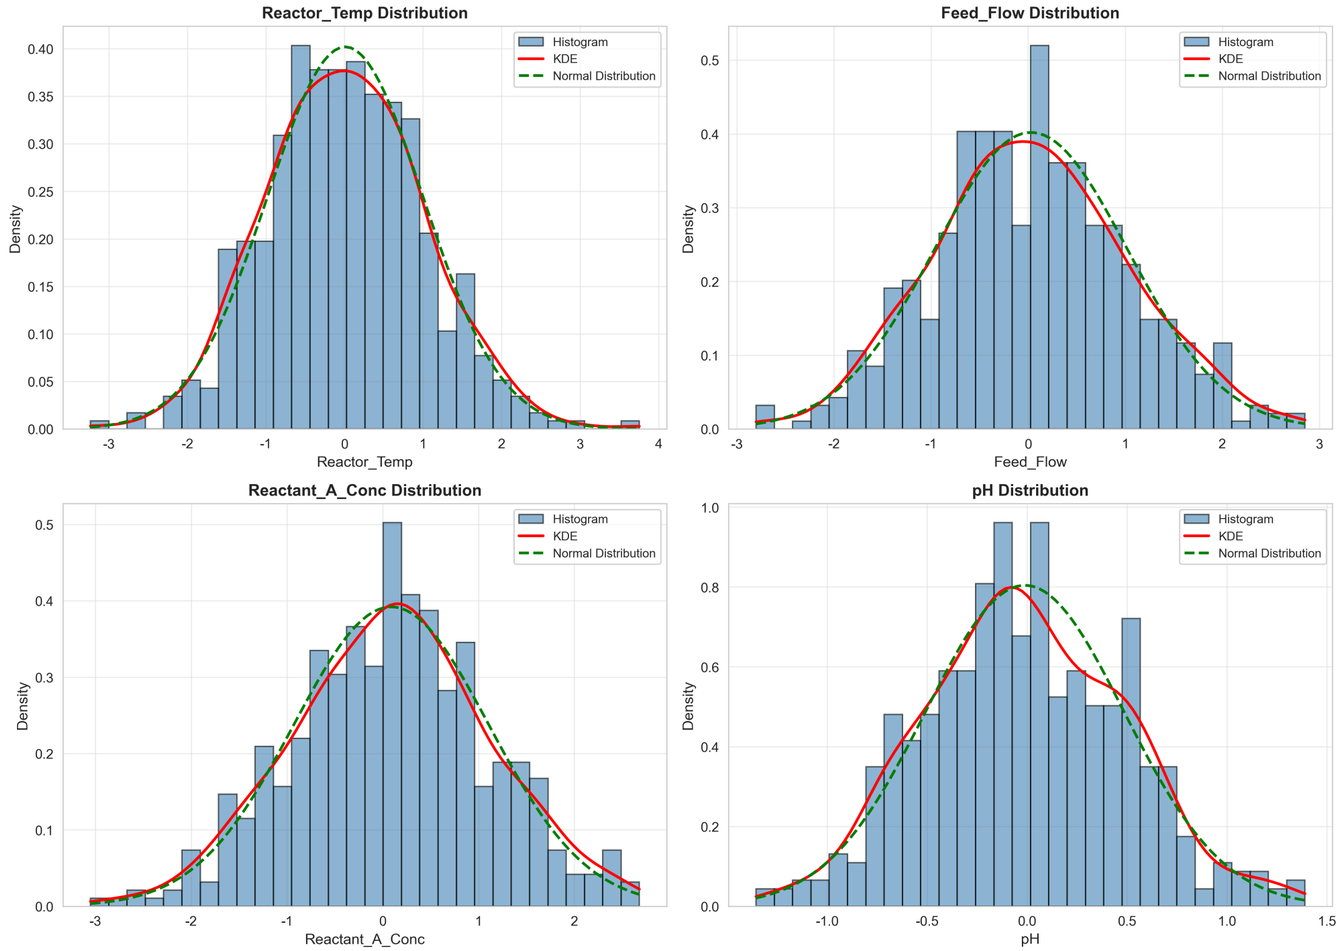


圖 1：CSTR 反應器 10 個製程變數標準化後之數值分布直方圖。 紅色虛線標示平均值 $\mu = 0$，所有特徵均勻分布在標準常態區間內。

實戰案例：10 個製程變數之相關係數結構診斷 (EDA)

10 個感測器背後的 4 大物理耦合群組 CORRELATION STRUCTURE

- **群組 1 · 溫度強耦合三人組** ($r = 0.89 \sim 0.97$)：`Reactor_Temp`、`Jacket_Temp`、`Product_Temp` 受熱傳導支配高度同步，且與 `Reactor_Pressure` 呈中高度正相關 ($r \approx 0.67 \sim 0.72$)。
- **群組 2 · 流體力學與壓力控制組** ($r = 0.80 \sim 0.94$)：`Feed_Flow` 與 `Coolant_Flow` 高達 $r = 0.94$，且雙雙強烈帶動進料管線壓力 `Feed_Pressure` ($r \approx 0.80 \sim 0.81$)。
- **群組 3 · 反應物濃度雙人組** ($r = 0.92$)：`Reactant_A_Conc` 與 `Reactant_B_Conc` 按化學計量比同步消耗。
- **群組 4 · 完全獨立變數 (`pH`, $|r| < 0.05$)**：`pH` 與其餘 9 個變數相關係數皆趨近於 0！這預告了它**絕對無法被前三個共線主成分整併**。

FIG 02 // PEARSON CORRELATION MATRIX HEATMAP (10 × 10) FILE: correlation_matrix.png

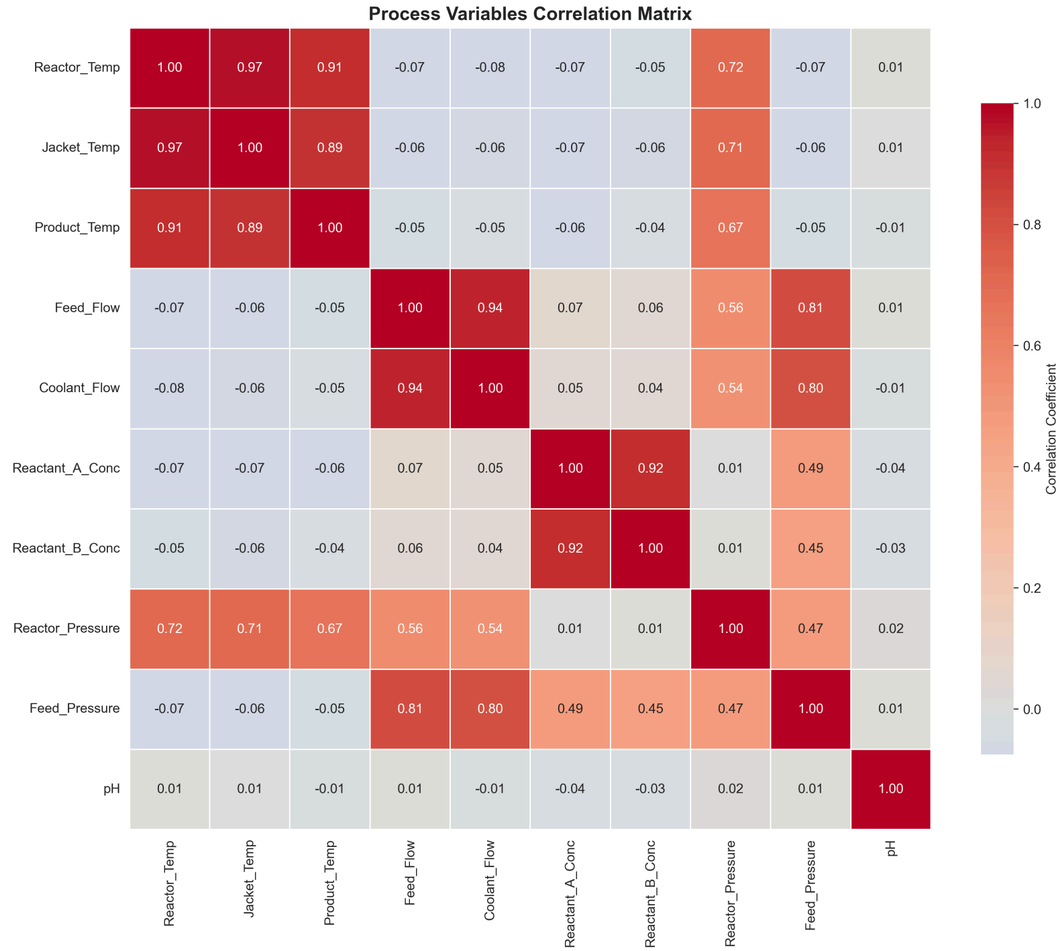


圖 2：10 個製程變數之皮爾森相關係數熱力圖。 深紅色區塊清楚浮現三大共線性物理群組，而最下排/最右欄的 `pH` 則呈現全白 ($r \approx 0$) 的獨立特性。

決定主成分數量 k (1)：解釋變異數完整分析與 PC4 的秘密

主成分變異數結構深度解讀

EIGENVALUE ANALYSIS

- **前 3 個主成分 (PC1 ~ PC3) 捕捉 85.26% 變異：**
  將原本 9 個高度共線的溫度、壓力、流量、濃度變數，濃縮為 3 個獨立的物理潛在變數。
- **關鍵發現：為什麼 PC4 剛好佔 9.99% ($\lambda_4 \approx 1.00$)？**
  • 在 10 個標準化變數中，每個變數自身貢獻 10% 的總變異數。
  • 因為 `pH` 與其他 9 個變數完全無關 ($|r| < 0.05$)，無法與任何變數合併降維，因此 PCA 專門指派 PC4 **百分之百代表** `pH` ！
- PC5 ~ PC10 **合計僅佔 4.75%：**
  對應共線變數之間的微幅隨機量測雜訊，捨棄它們能達到**濾除高頻雜訊 (Denoising)** 的效果！

CSTR 案例 PC1 ~ PC10 解釋變異數完整統計表

VARIANCE BREAKDOWN

主成分	特徵值 λ_m	單一解釋變異比例	累積解釋變異比例	工程與物理意義判讀
PC1	**3.557**	**35.50%**	**35.50%**	**✓ 保留 (k=1)：反應器整體熱力學狀態軸 (溫度群 + 反應器壓力)**
PC2	**3.116**	**31.10%**	**66.60%**	**✓ 保留 (k=2)：流體力學與冷卻負荷控制軸 (進料/冷卻流量 + 進料壓力)**
PC3	**1.870**	**18.66%**	**85.26%**	**✓ 保留 (k=3)：進料反應物濃度主導軸 (Reactant A & B 濃度)**
PC4	**1.001**	**9.99%**	**95.25%**	**⚠️ 獨立 pH 專屬通道：若選 k=3 則落入殘差空間 E，由 SPE 管制圖監控！**
PC5	0.136	1.36%	96.61%	✗ 捨棄：共線感測器間之次要隨機波動與量測雜訊
PC6	0.111	1.11%	97.72%	✗ 捨棄：隨機量測雜訊 (Noise Subspace)
PC7 ~ PC10	0.078 ~ 0.027	合計 2.28%	**100.00%**	✗ 捨棄：強耦合變數間極微小之殘餘共線差異 (純雜訊)

決定主成分數量 k (2)：碎石圖 (Scree Plot) 與工程取捨

主成分數量 k 的三大工程選取準則

SELECTION RULES

- **準則 1 · 累積解釋變異數門檻法 (80% ~ 90%)：**
  化工製程監控最常設定 **85% 門檻**。本例在 $k = 3$ 時達 **85.26%**，剛好跨過 85% 基準線。
- **準則 2 · 碎石圖手肘法 (Scree Plot Elbow)：**
  觀察右圖左半部特徵值陡降折線，在 PC4 → PC5 出現最劇烈的斷崖（由 9.99% 暴跌至 1.36%），顯示 PC5 之後全為雜訊。
- **準則 3 · Kaiser 準則 ($\lambda_m \geq 1.0$)：**
  對標準化數據而言，$\lambda_m \geq 1$ 代表該主成分解釋力大於單一原始變數。

為什麼本教材刻意選擇 $k = 3$ 而非 $k = 4$？
選擇 $k = 3$ (85.26%) 讓獨立變數 `pH` (PC4) 進入殘差子空間 E，這將完美示範：**就算某個變數沒被選入前 k 個主成分，SPE (Q) 管制圖依然能百分之百捕捉它的異常！**

FIG 03 // SCREE PLOT & CUMULATIVE EXPLAINED VARIANCE (THRESHOLD = 85%, k = 3) FILE: scree_plot.png

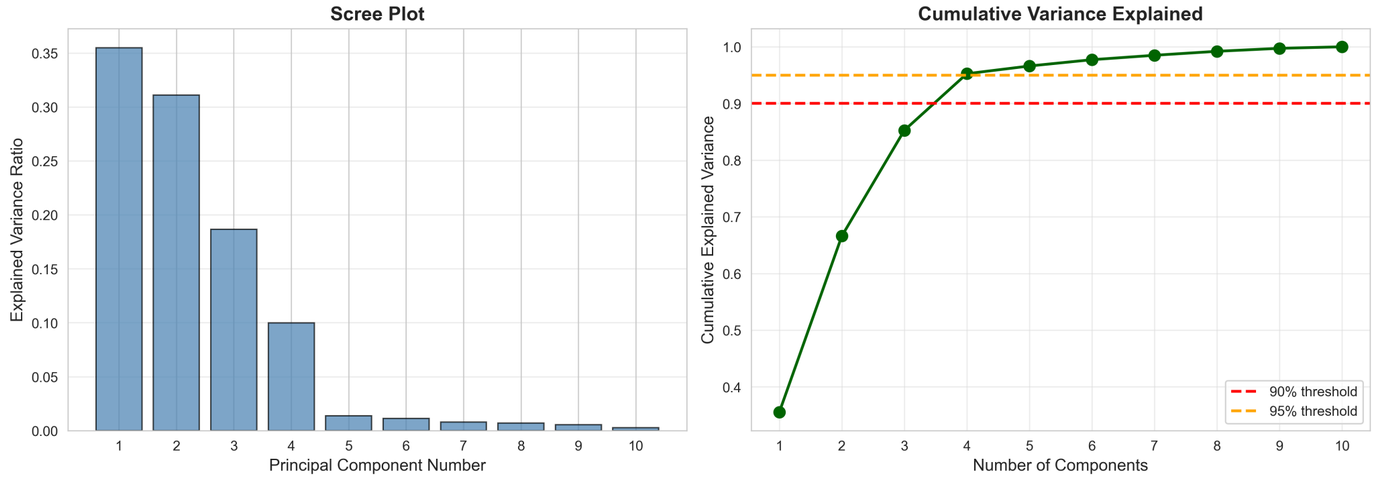


圖 3：碎石圖（左）與累積解釋變異數曲線（右）。 前 3 個主成分累積解釋 **85.26%** 變異數；加入 PC4 後達 **95.25%**，PC5 ~ PC10 則平坦貼近於零。

讀懂儀表板 (1)：Loadings 熱力圖 — 解碼主成分物理意義

解碼 PC1 ~ PC3 的化工物理意義

LOADINGS HEATMAP

- PC1 (35.50%) — **反應器熱力學狀態軸**：
  由 `Reactor_Pressure` (+0.505) 與三支溫度感測器 `Reactor_Temp` (+0.445)、`Jacket_Temp` (+0.444)、`Product_Temp` (+0.434) 共同主導，反映放熱反應之溫壓連動。
- PC2 (31.10%) — **進料/冷卻流量與壓力控制軸**：
  由 `Feed_Pressure` (+0.491)、`Feed_Flow` (+0.439)、`Coolant_Flow` (+0.432) 正向主導，且與溫度群呈負負荷 (−0.264 ~ −0.283)，反映冷卻水帶走熱量之負回饋效應。
- PC3 (18.66%) — **反應物濃度主導軸**：
  由 `Reactant_B_Conc` (+0.624) 與 `Reactant_A_Conc` (+0.619) 絕對支配。

關鍵警訊： 注意最底部 `pH` 在 PC1、PC2、PC3 的權重分別僅為 −0.011、−0.008、+0.025（幾乎為 0）！代表前三個主成分完全不包含 `pH` 資訊。

FIG 04 // PCA LOADINGS HEATMAP (FEATURE WEIGHTS ON PC1, PC2, PC3)

FILE: loadings_heatmap.png

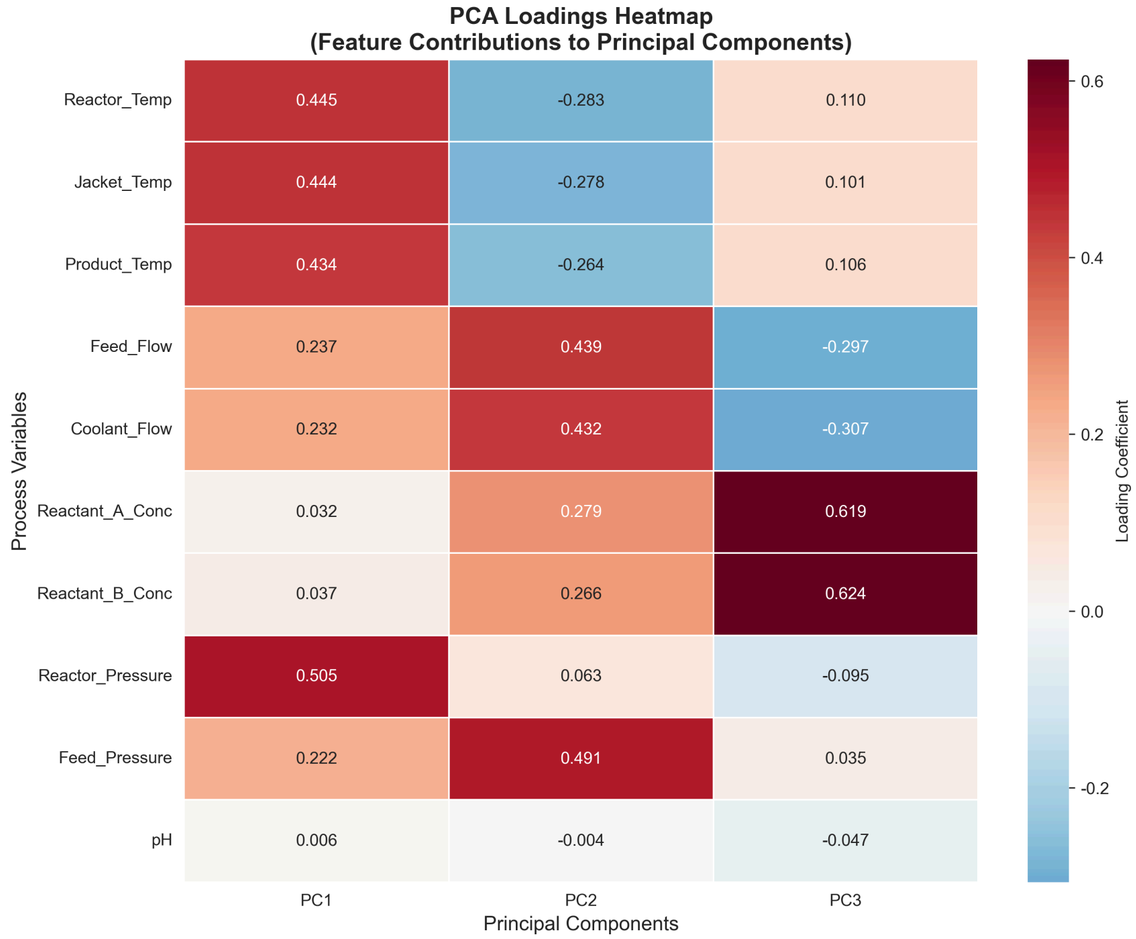


圖 4：前三個主成分之特徵負荷 (Loadings) 熱力圖。 每一欄滿足單位向量平方和 $\sum w_{jm}^2 = 1.0$，清楚將 9 個共線變數分流至三個正交物理通道。

讀懂儀表板 (2)：Loading Plot 特徵向量幾何判讀法則

Loading Plot 向量幾何判讀三大法則

VECTOR GEOMETRY

- **法則 1 · 箭頭夾角 $\theta \approx 0°$（同向重疊）：**
  代表變數間**高度正相關**！如右圖右下象限 `Reactor_Temp`、`Jacket_Temp`、`Product_Temp` 三支箭頭幾乎完全重疊；右上象限 `Feed_Flow` 與 `Coolant_Flow` 亦緊密並攏。
- **法則 2 · 箭頭夾角 $\theta \approx 90°$（互相垂直）：**
  代表兩群變數**近似獨立無關**（例如溫度群箭頭與流量群箭頭夾角接近直角）。若夾角 $\theta \approx 180°$ 則為強烈負相關。
- **法則 3 · 箭頭長度（距原點半徑）：**
  代表該變數在 PC1–PC2 平面上的**被解釋程度**。靠近單位圓周代表解釋力極佳；反之，`pH` **縮在原點** $(0, 0)$ **處**，代表它在 PC1–PC2 平面上完全隱形！

FIG 05 // 2D LOADING PLOT ON PC1 – PC2 PLANE (66.60% CUMULATIVE VARIANCE)

FILE: loading_plot.png

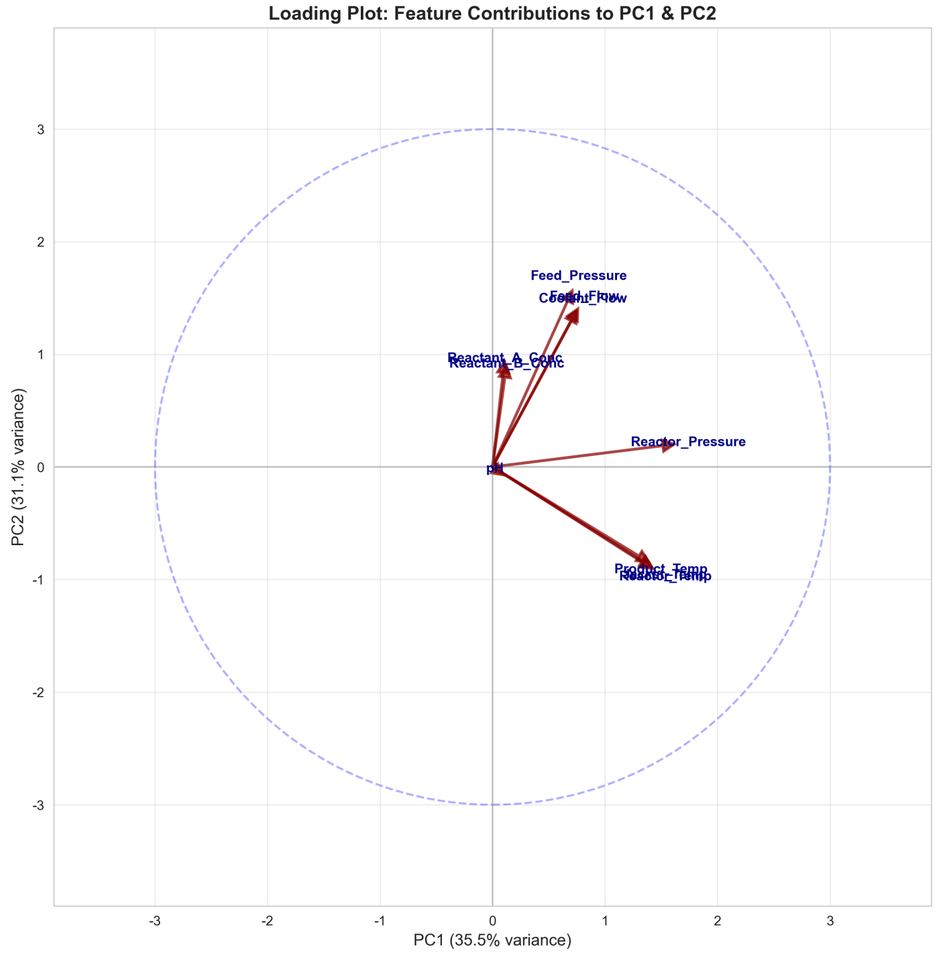


圖 5：PC1 vs. PC2 二維負荷向量圖 (Loading Plot)。 10 個製程變數在二維主成分平面上自然聚集成三大向量束，而 `pH` 則停留於原點。

讀懂儀表板 (3)：得分圖 (Score Plot) — 樣本空間定位與異常追蹤

得分圖 (Score Plot)：樣本空間定位雷達

SCORE SPACE

- **什麼是主成分得分 (Scores, t_i)？**
  每個時間點的樣本 x_i 投影到主成分軸上的座標值 $t_{im} = x_i^T w_m$。原點 $(0, 0, 0)$ 即代表**製程正常操作中心點**。
- **為什麼必須同時看 PC1–PC2 與 PC1–PC3？**
  因為我們保留了 $k = 3$ 個主成分，單看一張 2D 平面可能會漏掉發生在第三軸 (PC3 濃度軸) 的偏移。
- **追蹤兩個極端樣本的截然不同命運：**
  - ★ **Sample 209 (Max T^2)**：在 PC1 軸高達 **+8.77**，遠遠飛出正常樣本雲最右側邊界！
  - ◆ **Sample 194 (Max SPE)**：在兩張得分圖中都**安穩躲在原點附近 (T^2 = 3.41)**，單靠 Score Plot 絕對抓不到它！

FIG 06 // 2D PCA SCORE PLOTS: PC1 vs. PC2 (LEFT) AND PC1 vs. PC3 (RIGHT)

FILE: score_plot_2d.png

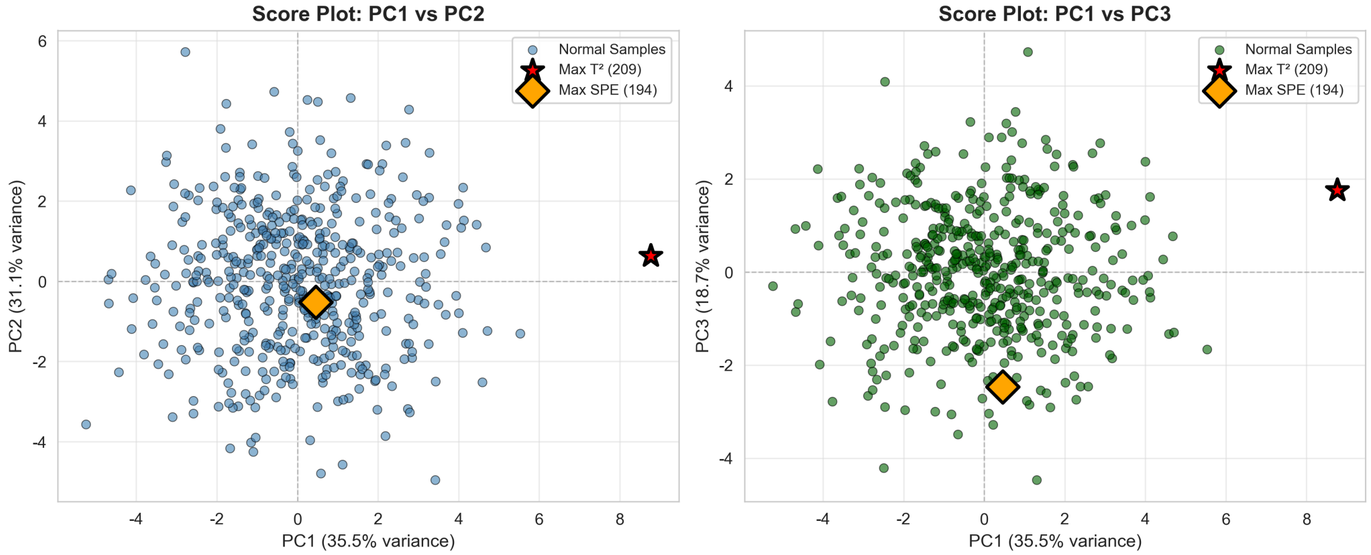


圖 6：主成分得分分布圖（彩色代表時間序列 0 ~ 499）。 紅色星號 ★ 標記 **Sample 209**（位於 PC1 極右端），橘色菱形 ◆ 標記 **Sample 194**（隱藏於正常樣本群中心）。

讀懂儀表板 (4)：雙標圖 (Biplot) — 樣本與特徵全景疊加診斷

雙標圖 (Biplot)：一張圖連結「樣本」與「變數」

BIPLOT OVERLAY

- **Biplot 的構造原理：**
  將「標準化至 [−1, +1] 的樣本得分點 (Scores)」與「特徵負荷箭頭 (Loadings)」疊加在同一張 PC1–PC2 座標平面上。

- **實務三步判讀法（以 ★ Sample 209 為例）：**
  1. **看樣本方位**：Sample 209 位於圖面**極右側略偏下方**。
  2. **找同向箭頭**：指向右下方的是 `Reactor_Temp`、`Jacket_Temp`、`Product_Temp` 與 `Reactor_Pressure`。
  3. **下工程結論**：Sample 209 是一個**「反應器整體高溫高壓極端操作點」**！無須查原始表格即可瞬間完成物理定性診斷。

> **注意：** ◆ **Sample 194** 位於原點附近，因為它的異常來自 `pH` (PC4)，必須進入下一節的 **SPE 殘差管制圖**才能現形！

FIG 07 // PCA BIPLOT: SIMULTANEOUS SAMPLE SCORES & FEATURE LOADINGS

FILE: biplot.png

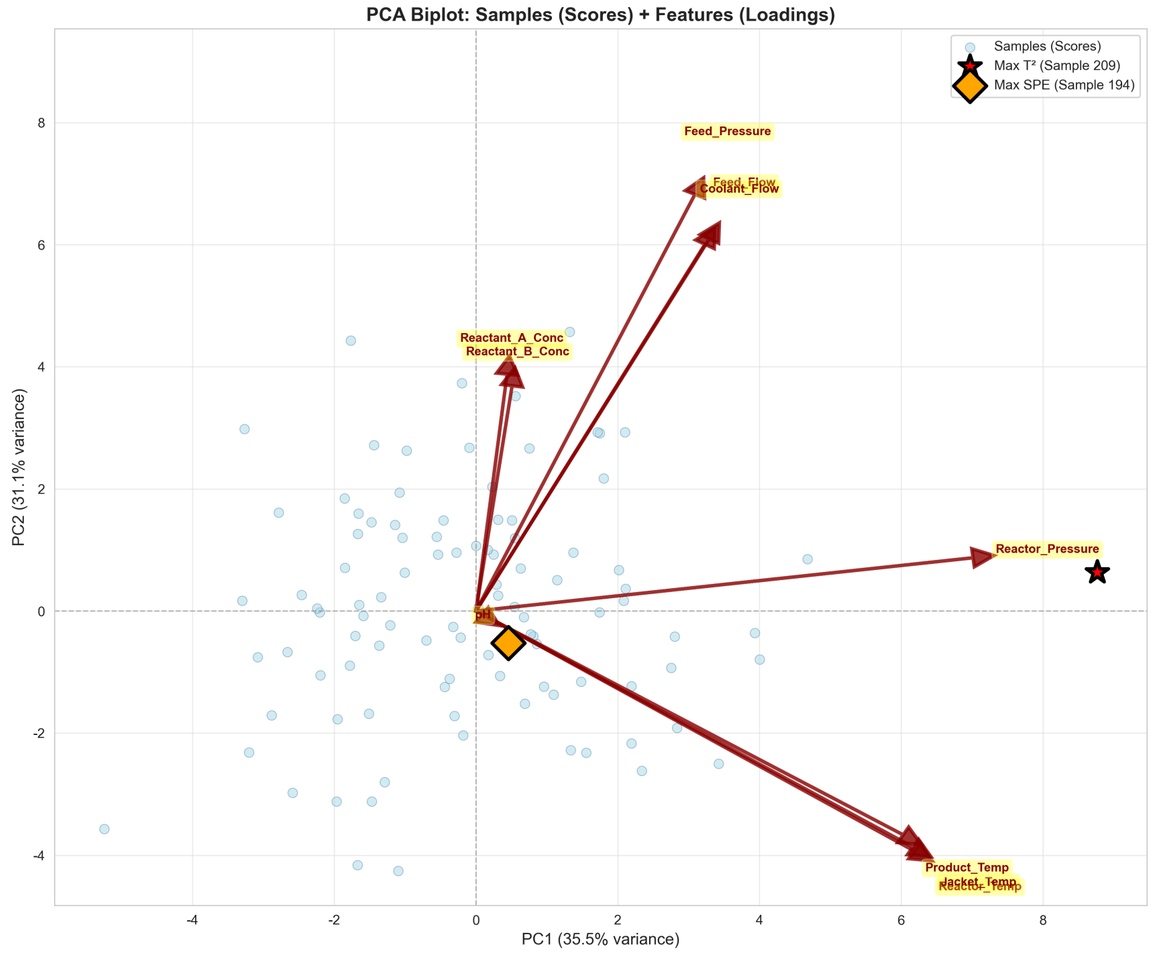


圖 7：PCA 雙標圖 (Biplot)。 樣本點朝哪支紅色特徵箭頭方向偏離，就代表該樣本在對應的物理感測器上出現顯著偏高數值。

工業雙軌監控理論 (1)：Hotelling's T² 與 SPE (Q) 統計量與幾何空間

DOC // U06-MSPC-18 | SCALE: 1:1 | REV: 2026.10

為什麼工業界需要「雙軌」統計量？ DUAL STATISTICS

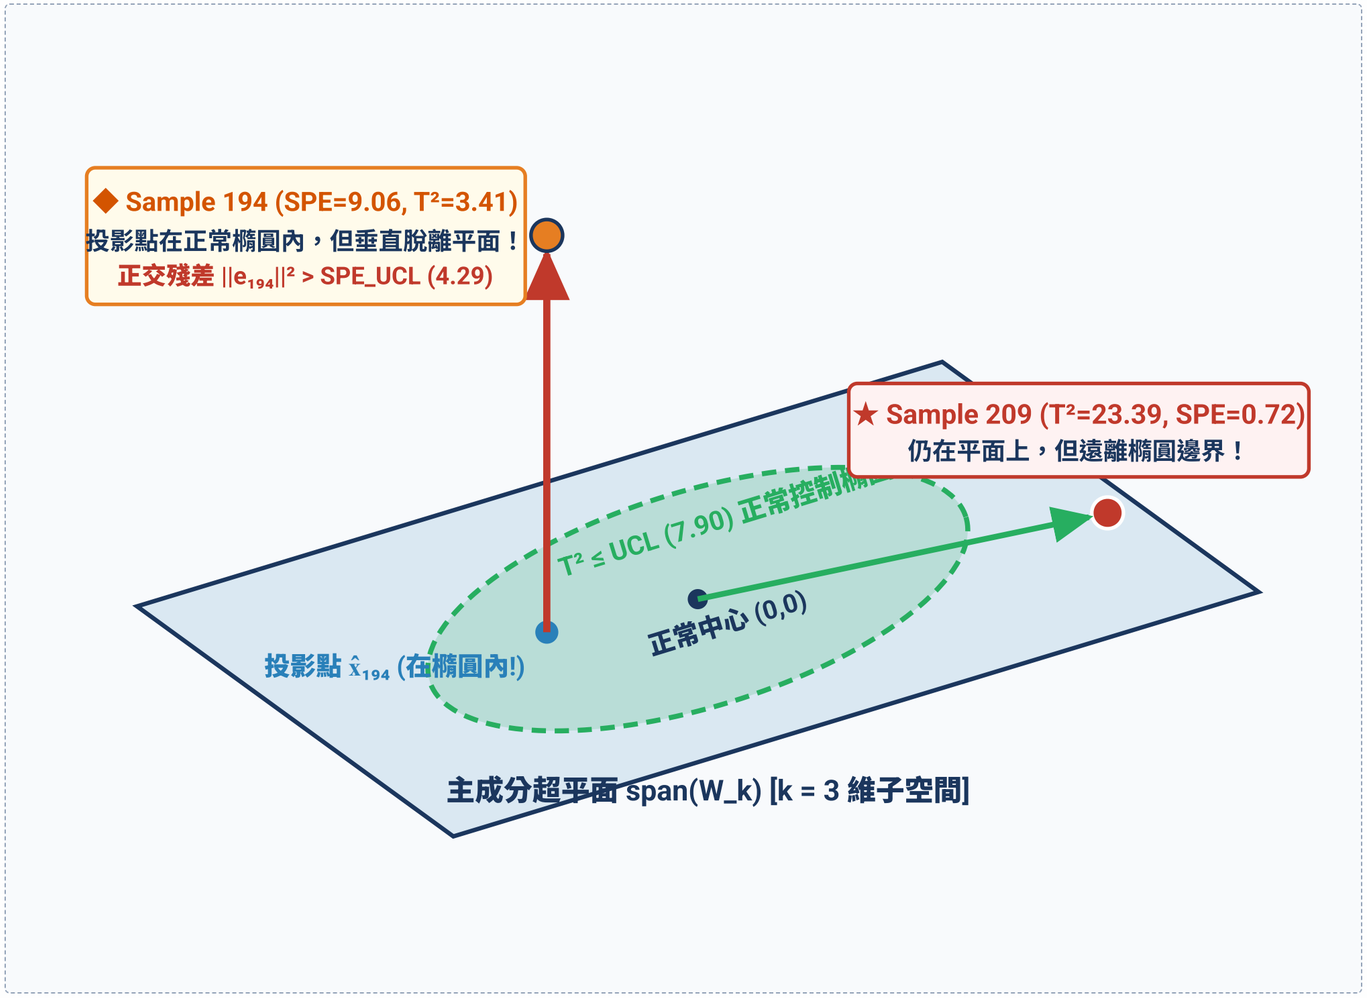
- **1. Hotelling's T^2（監控主成分子空間內部）：**
  將前 k 個主成分得分除以各自特徵值 λ_m 加總，幾何意義為**正規化馬氏距離 (Mahalanobis Distance)**，專門抓「模型已知耦合關係內的大幅度偏移」：

$$T_i^2 = \sum_{m=1..k} (t_{im}^2 / \lambda_m) = t_i^T \Lambda_k^{-1} t_i$$

- **2. SPE / Q 統計量（監控正交殘差子空間）：**
  計算樣本偏離主成分超平面的**正交殘差平方和**，專門抓「物理相關性破裂、感測器故障、或未納入前 k 軸之獨立變數異常」：

$$\mathrm{SPE}_i = Q_i = ||e_i||^2 = \sum_{j=1..p} (x_{ij} - \hat{x}_{ij})^2$$

三維空間幾何圖解：主成分子空間 (T² 管轄) vs. 殘差子空間 (SPE 管轄) SUBSPACE GEOMETRY



工業雙軌監控理論 (2)：控制上限 (UCL) 與四象限診斷矩陣

DOC // U06-MSPC-19 | SCALE: 1:1 | REV: 2026.10

控制上限 (UCL) 設定與統計假設

CONTROL LIMITS

- **1. Hotelling's T^2 控制上限（F 分布精確解）：**
  在得分服從多變數常態分布假設下（設信賴水準 $1-\alpha=95\%$）：

$$T_{\mathrm{UCL}}{}^2 = [k(n-1)(n+1)\,/\,n(n-k)] \cdot F_{\alpha}(k,\, n-k)$$

- **2. SPE (Q) 控制上限（經驗百分位數法 / Box 法）：**
  • 實務上最穩健做法為取正常訓練集殘差之 **95% 經驗百分位數**：`np.percentile(SPE_train, 95)`。
  • 理論近似則可用 Box (1954) 加權卡方分布 $g \cdot \chi_{h,\,\alpha}{}^2$。

- **型一錯誤 (False Alarm Rate) 預期值：**
  在 $\alpha = 0.05$ 下，正常數據本就會有約 **5% 樣本**自然落在 95% 邊界外，並非代表設備損壞！

工業雙軌監控四象限診斷決策矩陣 (Diagnostic Decision Matrix)

4-STATE DIAGNOSIS

T^2 狀態	SPE (Q) 狀態	幾何空間與物理意義	典型化工異常案例與處置
正常 (≤ UCL)	**正常 (≤ UCL)**	樣本位於主成分超平面上，且在正常控制橢圓內部。	✓ **製程正常穩定運作 (In-Control)**：所有變數與耦合關係皆符合歷史基準。
超標 (> UCL)	**正常 (≤ UCL)**	**模型內極端偏移：物理相關性仍維持完好，但整體操作負荷幅度過大。**	**★ 如 Sample 209：進料負荷大幅提升或環境溫升，導致溫壓成比例同步衝高。**
正常 (≤ UCL)	**超標 (> UCL)**	**模型外結構異常：變數間物理定律耦合破裂，或殘差空間獨立變數異常。**	**◆ 如 Sample 194：感測器結垢/漂移、冷卻閥卡死，或 `pH` 獨立通道異常。**
超標 (> UCL)	**超標 (> UCL)**	**全面失控狀態：既大幅偏離操作中心，又同時打破正常物理質量/能量平衡。**	**🚨 嚴重複合故障：如失控放熱反應 (Runaway Reaction) 或連鎖跳車前兆，需立即緊急介入！**

CSTR 製程監控實戰：T² 與 SPE 管制圖雙軌互補分析

CSTR 雙軌管制圖定量結果 ($\alpha = 0.05$)

MONITORING RESULTS

監控指標	Hotelling's T^2	SPE (Q 殘差)
95% 控制上限 (UCL)	7.900 (F分布)	4.289 (95% 百分位)
超標樣本數 (比例)	20 筆 (4.0%)	25 筆 (5.0%)
最大異常樣本編號	**Sample 209**	**Sample 194**
Sample 209 數值	23.389 (超標 3 倍!)	0.723 (完全正常)
Sample 194 數值	3.406 (完全正常)	9.063 (超標 2.1 倍!)

雙軌互補鐵證：

- 若只看 T^2 圖，會完全漏掉 **Sample 194** (T^2 = 3.406 < 7.900)！
- 若只看 SPE 圖，會完全漏掉 **Sample 209** (SPE = 0.723 < 4.289)！

兩張管制圖**缺一不可**！

FIG 08 // HOTELLING'S T² AND SPE (Q) CONTROL CHARTS (N = 500, ALPHA = 0.05)

FILE: control_charts.png

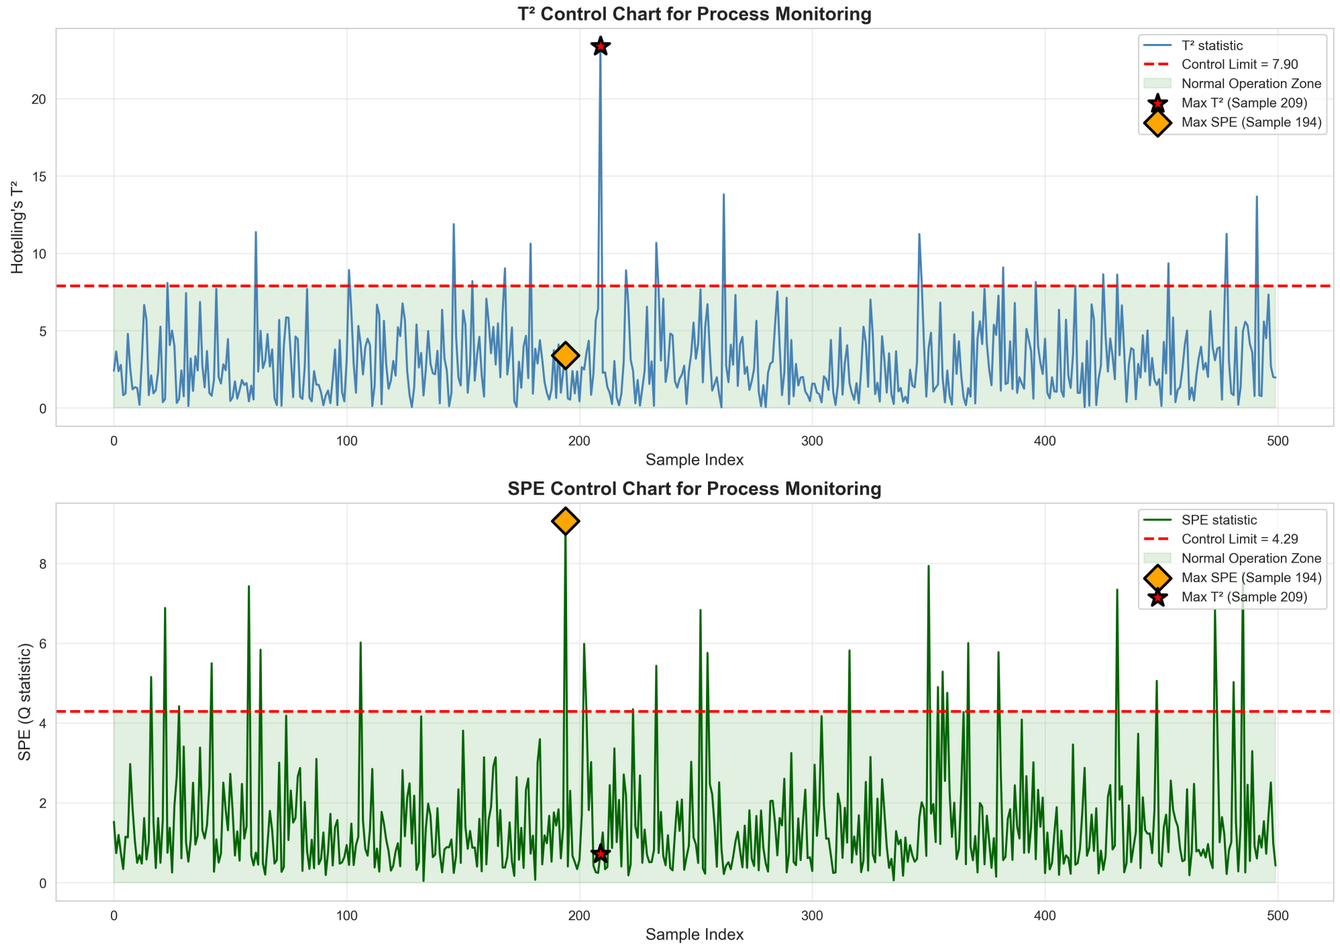


圖 8：Hotelling's T^2 管制圖（上）與 SPE 殘差管制圖（下）。 紅色虛線為 95% 控制上限 (UCL)，各自精準捕捉不同物理類型的極端樣本。

異常診斷實戰 (1)：Sample 209 (Max T^2) 共線群組貢獻圖剖析

異常根因診斷 (1)：Sample 209 (Max T^2)

SAMPLE #209 DIAGNOSIS

- **如何計算各變數對異常的貢獻度？**
  - **SPE 個別貢獻**：$\text{Cont}_{\text{SPE, j}} = (x_{ij} - \hat{x}_{ij})^2$（嚴格非負，加總即為總 SPE）。
  - **T^2 個別貢獻**：$\text{Cont}_{T^2\text{, j}} = \sum_{m=1..k} (t_{im} / \lambda_m)\, w_{jm}\, x_{ij}$。
- **剖析 Sample 209 (T^2 = 23.389, SPE = 0.723)：**
  - 下方 T^2 貢獻圖顯示前四大元兇為：`Reactor_Pressure` (5.52)、`Reactor_Temp` (4.31)、`Jacket_Temp` (4.28)、`Product_Temp` (4.09)。
  - 這四個 PC1 熱力學變數合計貢獻 **18.20（佔總 T^2 的 78%）**！

為什麼沒有單一根柱子突破紅色警戒線 (Mean+2σ = 6.095)？
這是**共線群組同步偏移 (Collinear Smearing)** 的典型現象！因為四個變數共同分攤了 PC1 的異常能量，但 SPE 極低 (0.723) 證明熱力學平衡關係完好無損。

FIG 09 // CONTRIBUTION PLOT FOR SAMPLE 209 (MAX HOTELLING'S T² = 23.389)　　FILE: contribution_plot_sample_209.png

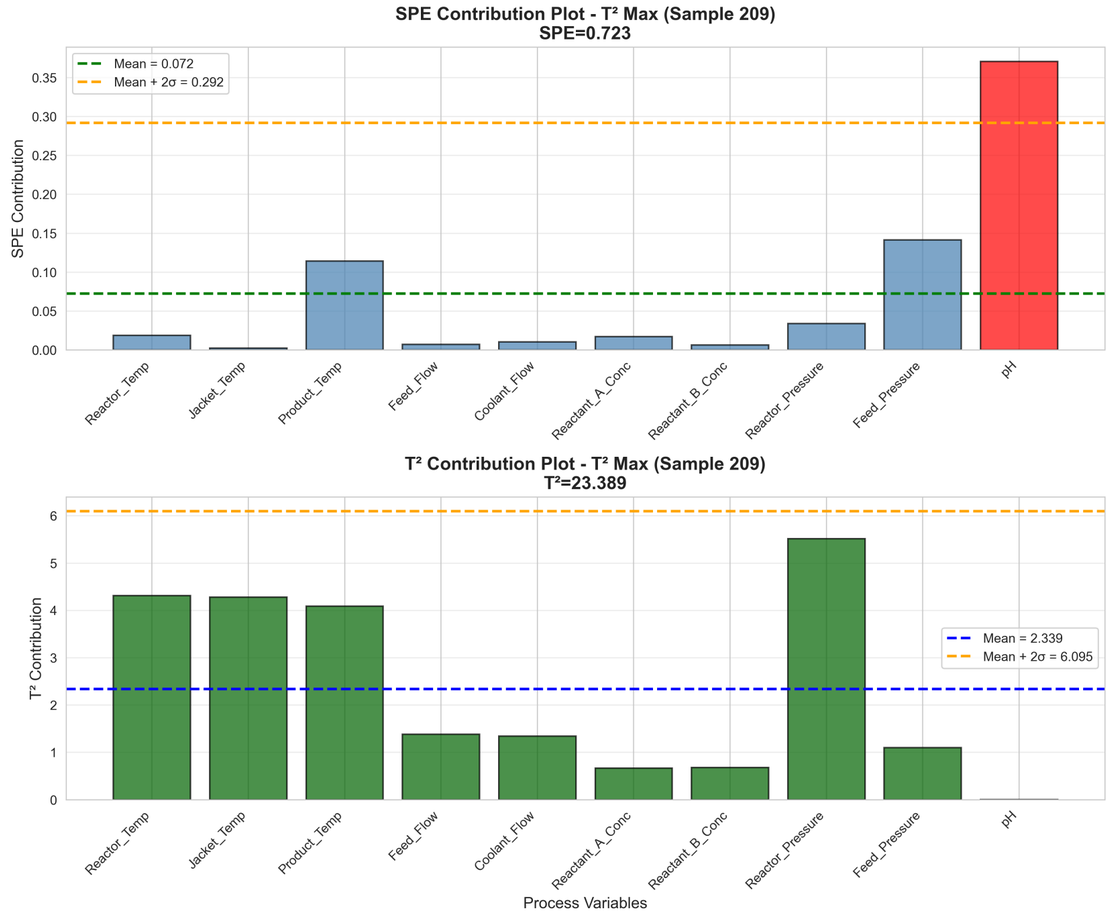


圖 9：Sample 209 之 SPE 與 T^2 貢獻圖。 下圖清楚顯示反應器壓力與三支溫度感測器同步呈現約 4.1 ~ 5.5 之高貢獻度。

異常診斷實戰 (2)：Sample 194 (Max SPE) — 捕捉遺漏的獨立變數

異常根因診斷 (2)：Sample 194 (Max SPE)

SAMPLE #194 DIAGNOSIS

- **剖析 Sample 194 (SPE = 9.063, T^2 = 3.406)：**
  - 觀察右圖上半部 **SPE 貢獻圖**：pH 單獨一根紅色長柱衝上 **8.0346**（遠超 Mean+2σ = 5.665 門檻），獨自佔了總 SPE (9.063) 的 **88.7%**！
  - 反觀右圖下半部 **T^2 貢獻圖**：pH 的貢獻度竟然是 **0.00**！
- **為什麼會出現如此戲劇性的對比？**
  - 因為我們只取前 $k = 3$ 個主成分，而獨立變數 pH 位於 PC4，完全不在 T^2 管轄的子空間內！
  - 當 Sample 194 的 pH 發生 −2.71σ 偏低異常時，重建值 $\hat{x}_{pH} \approx 0$，因此殘差平方 $(-2.71 - 0)^2 \approx 8.03$ 百分之百被 **SPE 殘差管制圖**精準攔截！

核心教學結論：「未被選入前 k 個主成分」**絕不代表被監控系統丟棄**——它只是移交給 **SPE (Q) 管制圖**全權負責！

FIG 10 // CONTRIBUTION PLOT FOR SAMPLE 194 (MAX SPE = 9.063, SINGLE VARIABLE pH FAULT)

FILE: contribution_plot_sample_194.png

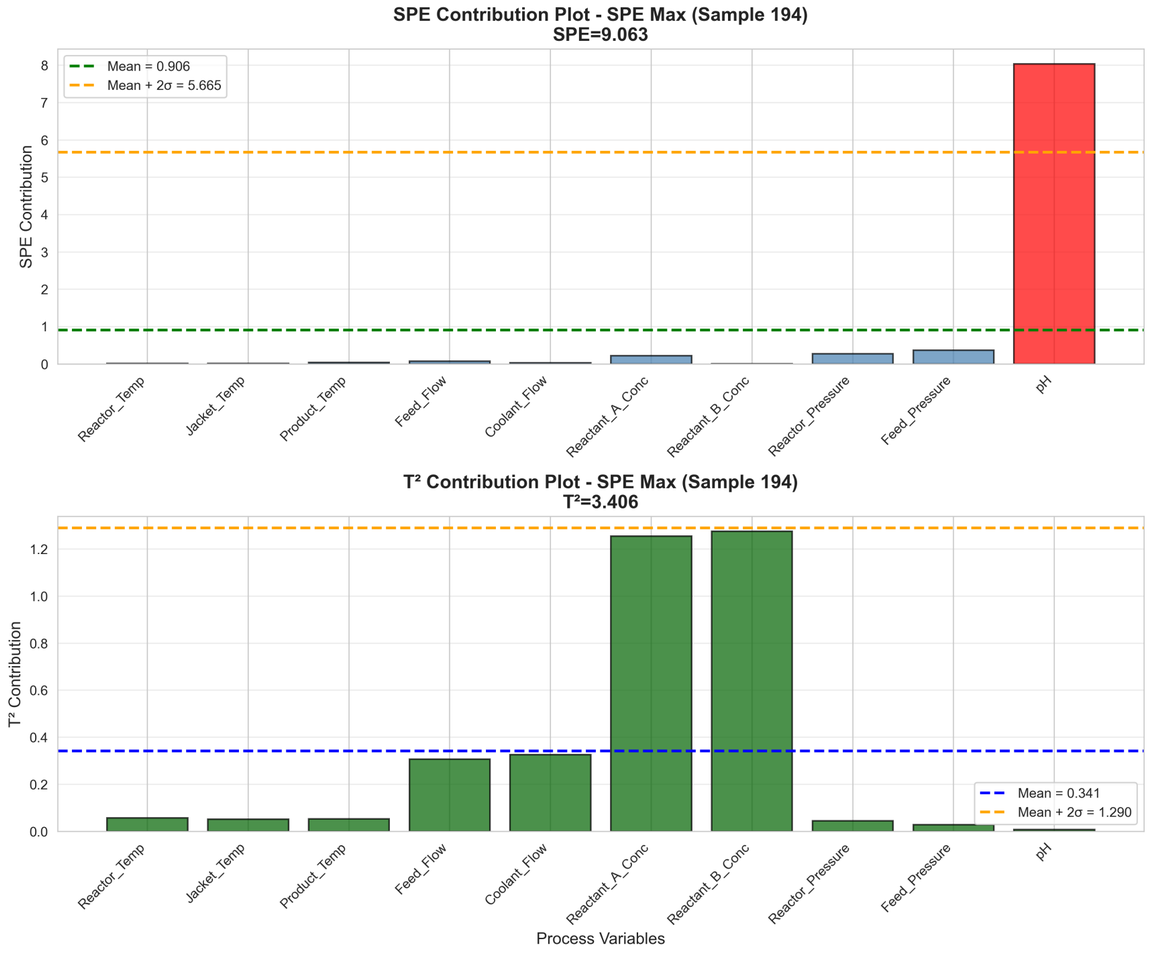


圖 10：Sample 194 之 SPE 與 T^2 貢獻圖。上圖 pH 一柱擎天（貢獻 88.7% SPE），下圖 pH 在 T^2 中貢獻則為 0.00。

生產環境部署與進階 PCA 變體 (PCR / Incremental / Sparse / DPCA)

DOC // U06-EXT-23 | SCALE: 1:1 | REV: 2026.10

工業部署：封裝與線上推論管線

MODEL DEPLOYMENT

- **生產環境必須同時儲存四項核心資產：**
  不能只存 `pca` 模型！必須將 `scaler`、`pca`、`T2_ucl` 與 `SPE_ucl` 一起封裝，確保線上推論標準完全一致。

```python
import joblib

# 1. 離線訓練完成後：封裝完整監控字典
monitoring_pkg = {
    'scaler': scaler,        # 含訓練集 μ 與 σ
    'pca': pca,              # 含 W_k (3×10) 與 λ_k
    'T2_ucl': T2_ucl,        # 7.900 (95% F-limit)
    'SPE_ucl': SPE_ucl,      # 4.289 (95% percentile)
    'features': feature_names
}
joblib.dump(monitoring_pkg, 'cstr_pca_monitor.pkl')

# 2. DCS 線上即時監控：載入並對單筆新數據 x_new 推論
pkg = joblib.load('cstr_pca_monitor.pkl')
x_std = pkg['scaler'].transform(x_new)
t_new = pkg['pca'].transform(x_std)
e_new = x_std - pkg['pca'].inverse_transform(t_new)
```

從標準 PCA 邁向進階工業變體 (Advanced Variants)

BEYOND VANILLA PCA

1. 主成分迴歸 (PCR)

`Pipeline([('scaler', StandardScaler()), ('pca', PCA(3)), ('reg', LinearRegression())])`

先以 PCA 轉成正交得分 T再預測產品指標 y，徹底解決軟感測器共線性震盪（詳見 Part 3 回歸單元）。

2. 增量式 PCA (IncrementalPCA)

`IncrementalPCA(n_components=3, batch_size=200)`

透過 `partial_fit()` 分批讀取百萬筆歷史庫數據，記憶體消耗固定，且支援催化劑緩慢老化之模型線上更新。

3. 稀疏主成分分析 (SparsePCA)

`SparsePCA(n_components=3, alpha=1.0)`

在負荷向量加入 L_1 (Lasso) 懲罰項，強迫次要特徵權重歸零，使每個主成分僅由少數 2 ~ 3 個關鍵感測器組成，物理可解釋性極高！

4. 動態與非線性擴展 (DPCA / KPCA)

- **時間序列自相關**：加入時間延遲矩陣 *[x(t), x(t−1), ...]* 建立 **Dynamic PCA (DPCA)**。
- **強非線性流形**：改用 **Kernel PCA**、**t-SNE / UMAP** (Unit 07) 或 **Autoencoder**。

實務常見五大陷阱與 Unit 06 工程實作總結檢查清單

DOC // U06-SUMM-24 | SCALE: 1:1 | REV: 2026.10

實務常見五大致命陷阱 (Pitfalls)

COMMON PITFALLS

- **陷阱 1 · 忘記做 Z-Score 標準化**：
  直接把溫度 (°C)、流量 (L/min) 與濃度 (mol/L) 丟進 PCA，結果第一主成分變成「流量計專屬通道」。
- **陷阱 2 · 對新數據重新呼叫 `fit_transform()`**：
  造成嚴重資料洩漏，異常樣本污染平均與標準差基準，導致管制圖失靈。
- **陷阱 3 · 將含故障的歷史資料混入訓練集**：
  PCA 建模必須使用**純淨正常操作數據 (In-Control Baseline)**，否則異常方向會被當成正常主成分！
- **陷阱 4 · 只看 T^2 卻不看 SPE (Q)**：
  漏掉如 Sample 194 (`pH` 異常) 或感測器漂移等違反物理相關性的結構故障。
- **陷阱 5 · 誤以為負荷向量正負號代表異常好壞**：
  特徵向量 w_m 乘上 -1 仍是合法特徵向量，重點在於**變數間的相對同號/異號關係**。

Unit 06 工程實作總結檢查清單 (Engineering Verification Checklist)

SUMMARY CHECKLIST

- **[✓] 數據品質與常態性檢查**：確認訓練集 X_{train} 為正常穩定操作區間，無極端離群值與嚴重缺失值。
- **[✓] 標準化無洩漏管線**：訓練集使用 `scaler.fit_transform()`，線上新樣本嚴格使用 `scaler.transform()`。
- **[✓] 主成分數量 k 綜合決策**：結合累積變異門檻 (85%)、碎石圖手肘點與物理意義，區分主成分子空間與殘差空間。
- **[✓] 物理意義解碼驗證**：繪製 Loadings Heatmap 與 Biplot，確認每個主成分對應明確的熱力學、流體或化學濃度機制。
- **[✓] 雙軌管制圖與貢獻圖閉環**：同時部署 **Hotelling's T^2 + SPE (Q)**，觸發警報時自動繪製貢獻圖定位根因感測器。

