


Elastic Net 回歸： 彈性網路與混合 正則化

破解多重共線性，建立穩健的
化工預測模型 | Unit 10



尋找特徵選擇與穩定性的完美平衡



Lasso (L1) 的極限

- 面對高度相關特徵時，會隨機盲選，極度不穩定
- 受限於樣本數，最多僅能選出 n 個特徵



Elastic Net 的突破


- 保留 Lasso 的稀疏性，自動剔除環境噪音
- 繼承 Ridge 的穩定性，完美對抗多重共線性
- 突破 $p > n$ 的特徵數量限制



Ridge (L2) 的極限

- 係數僅能收縮無法歸零，無法剔除噪音
- 模型龐雜，缺乏工程上的可解釋性


雙重收縮機制的運作原理



群組效應：讓高度相關的特徵同進同退


面對多重共線性時，不是互相排斥，而是共同承擔

Lasso 的盲選行為



隨機砍掉其一，失去物理意義與穩定性

Elastic Net 的群組效應



視為特徵群，同進同退，賦予兩者相似的權重

四大線性模型全方位評比

	OLS (最小平方法)	Ridge (L2)	Lasso (L1)	Elastic Net
特徵選擇能力	✗	✗	✓	✓
對抗多重共線性	極度敏感	穩健	不穩定	穩健
群組效應 (Grouping)	✗	✓	✗	✓ (改良版)
突破 $p > n$ 限制	N/A	無限制	最多 n 個	無限制


診斷結論：僅有 Elastic Net 在「特徵選擇」與「處理共線」兩大工業核心痛點上同時拿下滿分。

解決真實工程環境的高維度挑戰



多變數反應器

處理各區位高度相關的溫度與壓力操作變數，自動識別出真正影響產率的關鍵特徵群。




高維光譜數據

完美解決 NIR 或拉曼光譜分析中，測量波長維度 (p) 遠大於實際樣本數量 (n) 的數學瓶頸。



配方優化

精準捕捉多組分化學配方間的協同或拮抗效應，
精準捕捉多組分化學配方間的協同或拮抗效應，
有效剔除冗餘成分以簡化複雜配方。




流程監控與軟測量

從海量且具備高度物理相關性的感測器網路中，
從海量且具備高度物理相關性的感測器網路中，
自動識別核心變數並建立抗干擾的預測模型。

案例設定：測試模型對「共線性」的抵抗力

Data Architecture Flow

化工反應器實證數據
(n=500)



核心訊號 (4個)

溫度 (T), 壓力 (P), 催化劑 (C), 時間 (t)

真正影響產率

⚠ 共線陷阱區

溫度組陷阱：T1 (入口) 與 T2 (出口) [$r = 0.97$]

壓力組陷阱：P1 (入口) 與 P2 (出口) [$r = 0.99$]




噪音干擾

攪拌速度, pH 值

預測目標：
產率 (Yield)

工程任務：驗證模型能否看穿物理感測器的共線陷阱，
精準剔除噪音，並保留正確特徵群？

EDA：揭露變數間的高度相關性



散點圖驗證：呈現完美的線性分佈，傳統 OLS 模型在此必然發生係數爆炸或正負抵銷的崩潰危機。

群組效應實證：誰能做出最合理的決策？

Ridge 的補償錯誤

$$P1 = -2.3505$$

$$P2 = -2.0235$$

荒謬的負係數補償

壓力組陷阱
(P1, P2)

溫度組陷阱
(T1, T2)

Elastic Net 的完美決策

$$P1 = 0$$

$$P2 = 0$$

完美看穿，雙雙歸零


$$T1 = 0.9898$$

$$T2 = 0.5501$$

展現群組效應，同進同退穩健保留

對比 Lasso：Lasso 在處理溫度組時會不穩定地隨機切斷其中一項，而 Elastic Net 保證了物理意義上的完整性。

10 次隨機切分：生產環境需要的絕對穩定



穩定度壓力測試結論：

1. 核心訊號防護：兩種模型皆能 100% 抓住真正的關鍵特徵。
2. 噪音剔除一致性：對明顯噪音(P1)，皆能 100% 拒絕。
3. 群組一致性勝出：在高度共線的溫度組(T1/T2)中，Elastic Net 展現出遠高於 Lasso 的抓取穩定度。面對生產數據擾動，提供符合工業標準的預測一致性。

掌握雙參數控制台： α 與 $l1_ratio$

總強度 (α)



最佳值: 0.0475

決定要整體壓制多少雜訊。
數值越大，壓縮力道越強。

混合比例 ($l1_ratio$)

平衡混合



最佳值: 0.99

強多重共線性，
求穩定
(接近 Ridge)

強烈篩選特徵
(接近 Lasso)

實務指引：本案例數據因含有明顯的冗餘噪音，演算法自動將 $l1_ratio$ 落於 **0.99**，展現出極強的特徵篩選能力，並保留了 **1%** 的 L2 懲罰來維持群組穩定性。

使用 ElasticNetCV 進行自動建模



絕對前提！不可省略 **StandardScaler**。Elastic Net 對特徵尺度極度敏感，未標準化將導致懲罰失衡。

```
1 | scaler = StandardScaler()
2 |
3 | l1_ratios = [0.1, 0.5, 0.7, 0.9, 0.95, 0.99, 1.0]
4 |
5 | model = ElasticNetCV(l1_ratio=l1_ratios, cv=5,
6 |                       max_iter=10000)
7 |
8 | model.fit(X_train_scaled, y_train)
```

設定 l1_ratio 的搜索網格，涵蓋從偏向 Ridge 到偏向 Lasso 的各種可能。

初始化 ElasticNetCV，設定 5-Fold 交叉驗證自動尋找最佳參數組合。

進行訓練，模型將自動收斂並儲存最佳的 alpha 與 l1_ratio 屬性。

工業級建模的必備檢查清單



尺度對齊 (Scale)

特徵標準化是絕對前提！永遠在訓練前對數據執行 Z-score 轉換，確保正則化懲罰公平套用於每一個變數。



自動調參 (Auto-Tune)

放棄手動盲目測試。始終將 `ElasticNetCV` 列為首選工具，依賴交叉驗證讓數據自行決定最佳的 α 與 $l1_ratio$ 。



擾動測試 (Stability)

不要只看單一結果。透過多次交叉驗證 (CV) 確認特徵選擇的一致性，防範因單次資料切分造成的嚴重過擬合。



物理檢驗 (Physics)

不要盲信純數學算法。必須結合化工領域的專業知識，審視被演算法「同進同退」保留下來的特徵群，確認其是否具備真實的物理意義。

從理論到落地的完整掌握

Elastic Net 的三大核心價值

- ✓ 自動特徵選擇 (抗噪音)
- ✓ 強大預測穩定性 (抗共線)
- ✓ 獨特的群組效應 (保訊號)

下一步
學習路徑

→ Unit 10: 綜合比較所有線性模型 (作業與實作)

→ Unit 10: SGD_Regression (大規模工業數據解法)

→ Unit 11: 探索非線性建模方法 (跨越線性極限)