



Unit 10 Lasso 回歸 | Lasso Regression

L1 正則化與自動特徵選擇 (L1 Regularization & Automatic Feature Selection)




本單元學習目標 (Learning Objectives)



挑戰：高維數據的雜訊與過擬合 (The Challenge: High-Dimensional Data)


問題 (The Problem)



場景：一個現代反應器可能擁有 50+ 個傳感器 (溫度、壓力、流量、pH、攪拌速等)。

問題：並非所有變數都影響產率。若使用所有變數建模 (OLS)，會導致模型複雜、難以解釋且易過擬合 (Overfitting)。


解法 (The Solution)



解法：我們需要一個「過濾器」來自動保留關鍵變數，剔除冗餘雜訊。

核心概念：Lasso (Least Absolute Shrinkage and Selection Operator) = 稀疏性 (Sparsity) + 特徵選擇 (Feature Selection)。

Lasso 的運作機制：L1 正則化 (The Mechanism)



The diagram illustrates the Lasso loss function formula: $Loss = MSE + \alpha \sum |\beta_j|$. It features three callout boxes: a blue box for 'MSE' (Fitting Error), an orange box for ' α ' (L1 Penalty), and another blue box for the entire formula (Lasso Penalty). Arrows connect these boxes to their respective parts in the equation.

$$Loss = MSE + \alpha \sum |\beta_j|$$

擬合誤差 (Fitting Error) - 確保預測準確

Lasso 懲罰 (Penalty) - 確保預測準確


L1 懲罰項 (L1 Penalty) - 核心機制

懲罰絕對值和：迫使係數受到壓縮。


稀疏性 (Sparsity)：與 Ridge 不同，Lasso 能將不重要特徵的係數精確壓縮為 0 (Zero)，從而實現自動特徵選擇。

幾何直觀：為什麼 Lasso 會產生零？(Geometric Intuition)

Ridge (圓形約束) - 係數收縮但不為 0




Lasso (菱形約束) - 係數精確為 0



Lasso 的菱形約束容易與坐標軸相交，導致某些係數變為 0，這就是稀疏解的幾何成因。

調節閥：正則化強度 Alpha (α)



經驗法則：化工數據通常從 $\alpha=0.01$ 開始嘗試。必須使用交叉驗證 (Cross-Validation) 來尋找最佳 α 。

模型特性比較表 (Model Comparison)

特性 (Feature)	OLS	Ridge (L2)	Lasso (L1)
懲罰項 (Penalty)	無 (None)	$\sum \beta_j^2$	$\sum \beta_j $
特徵選擇 (Selection)	✗	✗ (保留所有)	✓ (自動剔除)
解的特性 (Solution)	無偏、高變異	收縮、非零	稀疏 (Sparse)
多重共線性	敏感 (不穩定)	穩健 (Robust)	隨機選擇其一
適用場景	簡單線性關係	所有特徵都重要	特徵多、需簡化模型

sklearn 實作與關鍵規範 (Implementation & Safety Protocols)

Python Code: LassoCV & Scaling

```
from sklearn.linear_model import LassoCV
from sklearn.preprocessing import StandardScaler

# CRITICAL: Lasso 對尺度極敏感，必須標準化
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)


# 使用 LassoCV 自動尋找最佳 alpha
lasso = LassoCV(cv=5, random_state=42)
lasso.fit(X_scaled, y)

print(f'Best Alpha: {lasso.alpha_}')
print(f'Coefficients: {lasso.coef_}')
```

! 資料標準化 (Standardization) 是必須的!


Lasso 的懲罰項對係數大小敏感。若不進行標準化，大尺度的特徵（如壓力 Pa）將被錯誤地懲罰。

化工領域的實際應用 (ChemE Applications)




反應器優化 (Reactor Optimization)

從 20+ 個操作變數中 (T, P, Flow, pH...) 找出真正影響產率的 **5 個關鍵因子**。



軟測量開發 (Soft Sensor)

選擇最相關的輔助變數來預測難以測量的品質指標 (如濃度、黏度)。




品質控制 (Quality Control)

識別導致產品缺陷的**根本原因** (Root Cause Analysis)，剔除無關的製程雜訊。

實戰案例：化學催化反應產率預測 (Case Study)

Signal - 真實訊號

Temperature (°C) →
Pressure (bar) →
Catalyst (wt%) →
Time (min) →



Noise - 干擾雜訊


△ ? -- Stirring Speed
△ ? -- Feed Rate
△ ? -- pH
△ ? -- Solvent Ratio

- 目標 (Goal)：驗證 Lasso 能否自動識別並剔除這 4 個雜訊變數，僅保留真實訊號。
- 樣本數 (n)：500 Batches


參數調校與最佳 Alpha (Tuning Alpha)

調校結果 (Tuning Results)

- 方法 (Method)：使用 5-Fold Cross-Validation 自動搜索。
- 結果 (Result)：最佳 $\alpha = 0.0423$ 。
- 特徵保留狀況 (Feature Selection Status)：輸入特徵總數 8 個，選定特徵數 7 個。
- 說明 (Explanation)：剔除 1 個完全冗餘特徵，大幅壓縮其他雜訊。




係數分析：訊號 vs. 雜訊 (Coefficient Analysis)




➔ **結論：Lasso 成功構建了一個稀疏且可解釋的模型。**

正則化路徑 (Regularization Path)



模型預測性能與穩定性 (Performance & Stability)



性能指標與結論 (Metrics & Conclusion)

R^2 : 0.903 (解釋 90% 變異)


RMSE: 2.98% (低誤差)

CV Standard Deviation: 0.0073 (高穩定性)

結論：模型在不同數據子集上表現一致，具有極佳的泛化能力，適合實際部署。


總結與最佳實踐 (Summary & Best Practices)

何時使用 Lasso?



- 特徵數多 ($p \gg n$)
- 需要特徵選擇與模型簡化
- 追求高可解釋性

限制與解法



- 多重共線性 (Multicollinearity)
-> 改用 Elastic Net

黃金法則 (Golden Rule)

- ⚠ 務必先進行標準化 (Standardization)
- 使用 LassoCV 自動選擇 α



下一步：Unit 11
Elastic Net
Regression

