



Unit 10 | Linear Models Regression Overview

線性模型回歸總覽： 建立 AI 化工應用的核心基石




[標籤]
數學基礎



[標籤]
sklearn 實作



[標籤]
化工實戰案例



解析線性預測的底層邏輯

$$\hat{y} = w^T x + b$$

預測值：目標產出
(如產率、Tg 值)

權重向量：物理影響力
大小 (正負相關)

特徵向量：感測器數據輸入
(如溫度、壓力)

偏置項：系統基準值
/ 環境常數

四大工程優勢

可解釋性強

權重直接反映特徵影響力

高效率

訓練速度極快，適合大規模數據


高泛化能力

不易過擬合

高穩定性


理論基礎完善，容忍雜訊

支撐模型運作的五大物理限制與假設




線性關係

特徵與目標呈
線性關聯




獨立性

觀測值互不干擾



同質變異

殘差變異數恆定



常態分佈

殘差服從鐘形曲線



無多重共線性


特徵間無高度重疊

實務最常見之挑戰

$$\text{損失函數} = \text{MSE} + \alpha \times \text{Penalty}$$


正則化兵器譜：控制模型複雜度的三種策略

Ridge (嶺回歸) | L2 正則化




- 特性：縮減權重、保留所有特徵
- 適用：處理多重共線性

Lasso 回歸 | L1 正則化



- 特性：將不重要的權重歸零
- 適用：高維度資料的特徵選擇

Elastic Net | L1 + L2





- 特性：混合 L1 與 L2 懲罰項
- 適用：特徵遠多於樣本數

SGD Regressor：驅動大規模數據的輕量化引擎

OLS 最小二乘法

SGD 隨機梯度下降



模組：`sklearn.linear_model.SGDRegressor`


`loss` 損失函數設定 (如 `squared_error`)

`learning_rate` 學習率策略

`penalty` 正則化類型 ('`l2`', '`l1`', '`elasticnet`')

`max_iter` 最大迭代次數

原料精煉：打造數值穩定的資料前處理產線



Pipeline 封裝機制：阻絕資料洩漏 (Data Leakage)

錯誤：測試集資訊提前洩漏，評估虛高



正確做法：Pipeline 封裝



工程效益：程式碼簡潔、
無縫接軌交叉驗證

品管儀表板：四種評估指標的工程決策矩陣


指標	異常值敏感度		跨資料集可比	核心工程用途
MSE		極高 (平方放大)	否	優化/訓練階段的 損失函數
RMSE		高	否 (限同資料集)	工程誤差報告最常用 (如偏差 2.5°C)
MAE		穩健 (低)	否	存在異常值 (Outliers) 的資料評估
R^2 (決定係數)		中	是 (無量綱百分比)	跨廠區/跨資料集的 模型性能比較



異常警示：當 $RMSE \gg MAE$ 時，代表系統中存在少數「極端大誤差」樣本，需立即排查是否為異常操作條件！


擺脫切分運氣：為什麼我們需要交叉驗證？

運氣陷阱 (The Luck Trap)



公式分解 (The Formula Breakdown)

$$L_{true} = L_{train} + \text{Variance} + \text{Bias}^2$$



交叉驗證能直接估計 L_{true} ，
消除過擬合假象。

K-Fold 機制解剖：全面性的壓力測試

5-Fold Cross-Validation Matrix



Aggregated
Metrics
Calculation

Mean (平均值)



真實泛化能力


Std (標準差)



LOOCV (留一法)：當化工廠數據極少 (<50筆) 時的極端版本。


尋找最佳操作點：超參數搜尋策略對決

Grid Search (網格搜尋)



- 地毯式搜索，遍歷所有組合
- 必定找到設定範圍內的最優解
- 計算成本極高 ⚠️


Random Search (隨機搜尋)



- 高維度空間隨機採樣
- 以極少計算資源逼近最優解
- 效率遠勝網格搜尋 ⚡

⚠️ 嚴禁資料洩漏：必須採用「巢狀交叉驗證 (Nested CV)」分離參數選擇與性能評估！

實戰部署：線性模型在化工廠的五大角色



實績解析：三大關鍵製程的 AI 優化案例




催化裂解反應產率

挑戰：高度相關的進料與操作特徵

解方：Ridge Regression
(處理共線性)

$$R^2 = 0.92$$

有效指導操作優化




聚合物 Tg 性質預測

挑戰：需從大量結構參數中找出關鍵因子

解方：Lasso Regression
(自帶特徵選擇)

$$R^2 = 0.88$$

成功篩選出 15 個關鍵描述符



蒸餾塔操作自動化

挑戰：需同時兼顧特徵篩選與穩定性


解方：Elastic Net

$$RMSE < 0.5\%$$


成功整合至控制系統

突破邊界：線性模型的限制與進階解法


限制 A：顯著非線性關係




[升級路線] 多項式回歸、決策樹、神經網路





限制 B：複雜特徵交互作用




[升級路線] 引入交互項、非線性核函數 (Kernel)



限制 C：高維度時序相依數據




[升級路線] ARIMA、LSTM 等深度時序模型



⚠ 提醒：製程數據常有時間相依性，需用 Time Series Split 驗證。

課程藍圖：Unit 10 的深度學習路徑



⚠ 行動呼籲：請確保已安裝 Python 3.8+ 及 scikit-learn，準備進入實作環節。