



Unit 10 線性回歸 (Linear Regression)

數位化工廠的基石：從數據中挖掘製程關係



stamped

學習目標 (Learning Objectives)



- **理解原理 (Theory)**：掌握最小二乘法 (OLS) 與損失函數的數學基礎。



- **掌握工具 (Tooling)**：使用 `sklearn.linear_model.LinearRegression` 建立模型。




- **確認邊界 (Constraints)**：理解線性回歸的五大假設與診斷方法。



- **實戰應用 (Application)**：執行化工反應器產率預測 (Reaction Yield Prediction) 專案。


線性回歸：最基礎的製程模型 (The System Diagram)



$$y = X\beta + \varepsilon$$

目標：找到最佳的權重參數 β (Regression Coefficients)，以描述輸入與輸出的線性關係。

數學原理：最小二乘法 (Ordinary Least Squares)



$$RSS = \sum (y_i - \hat{y}_i)^2$$


目標 (Goal): 最小化殘差平方和 (Minimize Residual Sum of Squares)。

直觀理解: 尋找一條直線，使得所有數據點到該直線的垂直距離平方和最小。

解析解 (Closed-form Solution):


$$\hat{\beta} = (X^T X)^{-1} X^T y \text{ (The Normal Equation)}$$

操作限制：模型假設 (Operational Constraints)




線性關係 (Linearity)

因變數與自變數需存在線性關聯。




獨立性 (Independence)

觀測值之間互不干擾 (無自相關)。




同質變異性 (Homoscedasticity)

誤差的變異數需為常數 (不隨 X 變化)。



常態性 (Normality)

殘差需服從常態分佈 $N(0, \sigma^2)$ 。



VIF < 10

無多重共線性 (No Multicollinearity)

特徵之間不應高度相關 (VIF < 10)。

實作工具：Scikit-learn API (Control Logic)

```
from sklearn.linear_model import LinearRegression → Import  
  
# 1. Instantiate (Create the machine)  
model = LinearRegression() → 建立物件  
  
# 2. Fit (Calibrate/Train)  
# X_train: Features, y_train: Target  
model.fit(X_train, y_train) → 訓練模型  
  
# 3. Predict (Operate)  
y_pred = model.predict(X_test) → 進行預測
```

Note: fit_intercept=True (默認開啟截距項)。


性能指標：品質控制 (Quality Control)

R^2 (決定係數)




解釋變異的比例 (0 到 1)。
 $R^2=1$ 代表完美預測。

RMSE (均方根誤差)




$\sqrt{\text{MSE}}$ 。單位與目標變數相同
(e.g., Yield %)。
對大誤差較敏感。

MAE (平均絕對誤差)




預測誤差的平均絕對值。
對異常值較不敏感。

化工領域應用場景 (Process Applications)




反應產率預測

$y = \text{Yield}$, $X = [T, P, \text{Conc}]$



軟測量 (Soft Sensing)

預測難測量的塔頂純度，
基於易測量的 T, P。



物性估算


QSPR 模型—根據分子
結構預測沸點或溶解
度。



異常檢測

比較實際值與模型預測
值，識別偏差。

實戰案例：催化反應器產率預測 (Case Study)



Project Spec

Scenario: 優化催化反應過程，建立操作參數與產率的定量關係。

Data Specs (n=500):


Inputs (X):

- Temperature (80-120°C)
- Pressure (1-5 bar)
- Catalyst (0.5-2.5%)
- Time (30-180 min)

Output (y): Yield (%)

數據探索與相關性分析 (Data Exploration)


Correlation Heatmap



Key Findings


- 1. 正相關 (Positive Correlation) : 催化劑濃度 (Catalyst) 與 壓力 (Pressure) 對產率有顯著正向影響。
- 2. 多重共線性檢查 (VIF Check) : 所有特徵 $VIF < 10$ (相關係數 < 0.1) , 確認特徵間獨立, 適合使用線性回歸。
- 3. 產率分佈: 呈現常態分佈 (Mean $\approx 94.45\%$) 。

模型訓練：特徵重要性 (Feature Importance)




Insight: 為了最大化產率，應優先調整催化劑濃度與壓力。

模型評估：預測 vs 實際 (Parity Plot)




Verdict: 模型在訓練集與測試集表現一致，無過擬合 (No Overfitting)。

殘差診斷：確認模型有效性 (Residual Diagnosis)



驗證線性與同質性 (Linearity & Homoscedasticity)



驗證常態性 (Normality)

Verdict: 殘差隨機分佈且服從常態，模型統計假設成立。

應用預測：新操作條件模擬 (Digital Twin Simulation)

Condition	Temp (°C)	Pressure (bar)	Catalyst (%)	Pred Yield (%)
Low	90	2.0	1.0	75.50%
Med	100	3.5	1.5	93.75%
High	110	4.5	2.0	111.75%

Takeaway: 可在實際投料前，通過模型快速評估不同操作策略的預期產出。

總結與下一步 (Summary & Next Steps)

Linear Regression

- 優勢: 簡單、計算快、可解釋性強 (White-box model)。
- 限制: 無法處理非線性 (Non-linear)。
- 限制: 對異常值敏感 (Sensitive to Outliers)。

Advanced Modules

- 遇到多重共線性?
- Unit 10 Ridge / Lasso Regression.
- 遇到非線性?
- Polynomial Regression / Trees.