


Unit 10 隨機梯度下降回歸 (SGD Regression)

駕馭化工大數據與在線學習的高效引擎




為什麼需要 SGD？突破大數據運算的瓶頸

當化工數據量從實驗室等級 ($N < 10^4$) 擴展到工廠 DCS 等級 ($N > 10^6$) 時，傳統算法面臨「記憶體溢出」與「計算過慢」的挑戰。

Traditional Method (BGD)

批量梯度下降 (BGD)



全量載入
(Load All)


停機運算
(Stop & Calculate)

High Memory / Slow Speed

Complexity: $O(n)$

Our Solution (SGD)

隨機梯度下降 (SGD)




流式輸入
(Streaming)

即時運算
(Instant Calc)

Low Memory / Fast Speed

Complexity: $O(1)$

運作機制比較：尋找最佳解的路徑



核心概念：**SGD** 每次迭代僅隨機抽取 **1 個樣本** 計算梯度，犧牲了單步的精確度，換取了**極致的迭代速度**。

數學原理：拆解引擎核心構造

模型參數 (Model Parameters)

如反應器溫度的控制係數

$$\beta_{new} = \beta_{old} - \eta \cdot \nabla L(\text{Sample}_i)$$

學習率 (Learning Rate)

控制更新步長 (Step Size)。
步子太大會錯過，太小走不到。

隨機梯度 (Stochastic Gradient)

基於「單個樣本」計算出的下降方向。

目標函數：最小化 $J(\beta) = \text{Loss} + \text{Penalty}$

損失函數 (Loss Functions)：適應不同的工況環境

根據數據的「雜訊程度」選擇合適的模組

Squared Loss (平方損失)



標準工況。計算最快，但對異常值極度敏感。

`loss='squared_error'`

Huber Loss (Huber 損失) 化工推薦



雜訊工況。結合平方與絕對值損失。抗異常值干擾 (Robust)。


`loss='huber'`

Epsilon-Insensitive




容忍微小誤差。類似 SVR 的邏輯。

`loss='epsilon_insensitive'`



正則化 (Regularization)：防止過擬合的閥門




關鍵參數控制面板 (Control Panel)



「操作紅色警戒：特徵標準化」



若特徵未經縮放（例如：溫度 300K vs 壓力 1.5 bar），梯度下降會走入狹長的「山谷」，導致震盪無法收斂。



```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
# 務必先 fit 再 transform
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)
```


強制規範：所有特徵必須轉換為 $\mu = 0, \sigma = 1$ 。

在線學習 (Online Learning)：流式數據處理

1. 函數：partial_fit() - 增量更新模型，無需重置。


2. 應用場景：

- 即時監控 (Real-time Monitoring)
- 設備老化追蹤 (Equipment Degradation)
- 概念漂移 (Concept Drift)



數據流實時更新趨勢
(Real-time Data Stream Trend Update)

實戰驗收：化工反應器產率預測



設備：
CSTR 反應器

數據量：
50,000 筆歷史操作
數據

挑戰：
包含 **5%** 傳感器異常值
(Outliers)

目標：
建立穩健的產率預測模
型

訓練結果：極速收斂與特徵解析

Epochs: 91

收斂速度


Test R^2 : 0.8083

模型準確度

RMSE: 8.2057

預測誤差

Feature Importance



SGD 成功捕捉了反應動力學物理意義：溫度與時間正相關，**流速過快負相關**。

異常值對抗：Loss Function 的選擇至關重要



Metric	Squared Loss	Huber Loss
MAE	3.228	3.218 (Better)
Outlier Handling	Sensitive	Robust
Recommendation	Clean Data	Dirty Data

對於含 5% 異常值的化工數據，Huber Loss 提供更穩健的預測。

模型性能總體檢：SGD vs 傳統算法

Comparison Matrix	Accuracy (R^2)	Memory	Scalability
SGD Regressor	0.808 (Tie)	$O(1)$ (Low)	High (>1M)
Ridge / Lasso	0.810 (Tie)	$O(N)$ (High)	Low (<100k)

Decision Flowchart



在大數據維度上，SGD 完勝傳統方法。

故障排除指南 (Troubleshooting Checklist)



結語：您的數位工具箱已升級



大數據專武

$O(n)$ 效率處理百萬數據。



動態適應

利用 ``partial_fit`` 即時監控。



工業魯棒性

Huber Loss 對抗雜訊。



下一步 (Next Step)：
開啟 ``Unit10_SGD_Regression.ipynb``

現在就開始您的 50,000 筆數據實作練習！