



AI 在化工上之應用 / 模組十二

分類模型總覽 (Classification Models Overview)




從數學原理、演算法解構到工業應用的完整
工程指南。

機器學習管線旅程 (The Machine Learning Pipeline)




分類問題的輸出維度 (Dimensions of Classification)

二元分類 (Binary)




目標僅有正/負兩類
(例：反應成功/失敗)

多元分類 (Multi-class)




目標具三個或以上互斥類別
(例：產品分級)

多標籤分類 (Multi-label)



單一樣本可具備多重屬性
(例：化學品複合危害)

從回歸到分類：機率的映射與決策 (From Regression to Classification)



連續數值預測
(回歸輸出)

激活函數 (Sigmoid / Softmax)
- 將數值壓縮為 0~1 的機率分佈


決策閾值 (Threshold)
- 機率大於閾值則判定為特定類別

釐清盲點：分類 (Classification) vs. 分群 (Clustering)



分類 (監督式學習)

需要標籤。學習已知類別的邊界。



分群 (非監督式學習)

無需標籤。發現資料中的自然結構。

故障檢測的組合策略


第一階段：缺乏歷史標籤
→ 使用**分群**找出異常軌跡 → 工程師確認並貼標。



第二階段：累積足夠標籤
→ 訓練**分類**模型實現自動化診斷。

演算法解構 I：線性機率與最大邊界 (Linear vs. Margin)


邏輯迴歸 (Logistic Regression)



`sklearn.linear_model.LogisticRegression`

最小化對數損失 (Log Loss)。適用線性可分、需要機率輸出與高可解釋性之場景。

支持向量分類 (SVC)



`sklearn.svm.SVC`

透過核函數 (Kernel) 處理非線性。僅依賴少數支持向量決策，對異常值具容忍度。

演算法解構 II：樹狀決策與集成學習 (Trees & Ensembles)

決策樹 (Decision Tree)



`sklearn.tree.DecisionTreeClassifier`

根據特徵門檻分層決策。無需特徵標準化，具備完美的業務邏輯可解釋性。

梯度提升 (Gradient Boosting)

`sklearn.ensemble.GradientBoostingClassifier`



加性模型 (Additive Model)。依序建立淺層樹，後一棵樹專注修正前一棵的誤差，追求極致準確度。


演算法解構 III：條件獨立與機率推論 (Probabilistic Inference)

高斯貝氏分類器 (Gaussian Naive Bayes)

$$P(y|x) = \frac{P(x|y) * P(y)}{P(x)}$$

貝氏定理：透過先驗機率與特徵概似度，反推分類機率。

- 假設特徵之間條件**獨立** (Naive)。
- 假設特徵服從高斯分佈。



`sklearn.naive_bayes.GaussianNB`

優勢：訓練/預測極快、參數極少不易過擬合。

限制：獨立性假設在真實化工數據中常不成立。

分類演算法決策矩陣 (Algorithm Selection Matrix)

模型	線性/非線性	可解釋性	訓練速度	適合資料量	特徵標準化
Logistic Regression	線性	☆☆☆	快	中~大	✅ 必須
SVC	非線性	☆	慢	小~中	✅ 必須
Decision Tree	非線性	☆☆☆	快	中	❌ 不需
Gradient Boosting	非線性	☆☆	慢	中~大	❌ 不需
Naive Bayes	非線性	☆☆☆	極快 🏎️	小~中	— 視情況

資料整備：對抗類別不平衡 (Handling Imbalanced Data)



常見挑戰：模型容易偏向樣本數多的多數類


類別權重調整 (Class Weighting)



```
class_weight='balanced'
```

透過數學公式提高少數類樣本的懲罰權重。

重採樣技術 (Resampling)




物理改變資料量：過採樣增加少數類；欠採樣減少多數類。

決策閾值調整 (Threshold Tuning)




在預測階段改變決策門檻，提高少數類的判定敏感度。

模型評估 I：混淆矩陣與核心指標 (Confusion Matrix)



模型評估 II：ROC 曲線與 AUC (Model Capability)



AUC 1.0 (完美)



AUC > 0.8 (良好)



AUC = 0.5 (隨機猜測)

ROC 曲線衡量模型在不同閾值下，分辨正負類別的綜合能力。曲線下面積 (Area Under Curve) 代表模型的「分辨力」。面積越大，分類能力越強。

模型調校與決策對齊 (Tuning & Metric Selection)



分層 K-折交叉驗證 (Stratified K-Fold) : 確保每折資料分佈一致，為超參數網格搜索 (Grid Search) 提供穩健基礎。

業務需求 (化工場景)		推薦優化指標
場景 1：設備故障檢測、安全監控 (絕不能漏檢危險)	➡	優化 Recall (召回率)
場景 2：產品品質分級 (避免錯殺好品)	➡	優化 Precision (精確率)
場景 3：嚴重類別不平衡的綜合預測	➡	優化 F1-Score / AUC
場景 4：需要精確風險機率輸出	➡	優化 Log Loss (對數損失)

工具的選擇服膺於工程目的：若需決定是否停機檢修，用分類；若需預測具體產量，用回歸。