



The diagram illustrates Support Vector Classification (SVC) on a 2D grid. A thick black line represents the decision boundary separating two classes of data points: blue circles in the upper-left and grey circles in the lower-right. Two orange circles, representing support vectors, are positioned on the decision boundary. Arrows indicate the perpendicular distance from the decision boundary to the nearest data points of each class. A label 'Support Vectors' with arrows points to the orange circles. A dashed circle and a crosshair are also visible in the upper-left quadrant.

支持向量分類 (Support Vector Classification)



從幾何邊界到精準分離的工程藍圖

單元：Unit12

領域：AI在化工上之應用

授權：CC BY-NC-SA 4.0

從『擬合管道』到『最大化間隔』



概念	SVR（回歸）	SVC（分類）
學習目標	最佳擬合函數（迴歸線）	最優決策超平面（分界面）
最優化準則	樣本盡量落在 ϵ -管道「內」	兩個類別的樣本盡量分隔「遠」
損失函數	ϵ -insensitive loss	Hinge loss
鬆弛變數 ξ	管道外樣本的超出量	間隔違反量（誤分類懲罰）
輸出	連續數值 $\hat{y} \in \mathbb{R}$	類別標籤 $\hat{y} \in \{-1, +1\}$

SVR 與 SVC 的共用數學核心

對偶問題 (Dual Problem)
框架與核函數機制完全相同。

$$\max_{\alpha} \sum \alpha_i - \frac{1}{2} \sum \alpha_i \alpha_j y_i y_j K(x_i, x_j)$$

$$\text{s.t. } 0 \leq \alpha_i \leq C, \sum \alpha_i y_i = 0$$


SVR 預測

直接輸出
 $f(x) = \sum \alpha_i y_i K(x_i, x) + b$
作為連續預測值。

SVC 預測

對 $f(x)$ 取符號函數 $\text{sign}(f(x))$ ，
轉換為 $\{-1, +1\}$ 類別標籤。

SVC：核心幾何解釋



決策邊界 (Decision Boundary) :
 $w^T x + b = 0$
(法向量 w 決定方向，偏置項 b 決定位置)


間隔 (Margin): $2 / \|w\|$
SVC 的核心目標就是最大化這個距離。

支持向量 (Support Vectors) :
滿足 $y_i(w^T x_i + b) = 1$ 的關鍵樣本。
其他樣本對模型的邊界無影響。

軟間隔：工程公差與鬆弛變數 (ξ)


允許部分樣本違反間隔約束，引入鬆弛變數 ξ_i (Slack Variable) 來衡量違反程度。

硬間隔 (Hard Margin)



限制：對噪聲極度敏感，僅適用線性可分。

軟間隔 (Soft Margin)




允許部分樣本違反間隔，提高魯棒性。

目標函數： $\min \frac{1}{2} \|w\|^2 + C \sum \xi_i$
 $C \sum \xi_i$ 構成對誤分類樣本的懲罰機制。


懲罰參數 C ：誤差容忍度的控制旋鈕

High C
(大數值)



- 嚴格懲罰違反間隔的樣本。
- 間隔較小，決策邊界複雜。
- 風險：容易過擬合 (Overfitting)。



Low C
(小數值)




- 允許更多違反，間隔較大。
- 決策邊界平滑，泛化能力可能較佳。
- 風險：可能欠擬合 (Underfitting)。

核技巧 (Kernel Trick)：維度轉換的幾何魔術

2D 空間：無法用直線分離。







高維空間：變為線性可分。



映射機制：定義映射函數 ϕ ，將低維數據映射到高維特徵空間。

核心技巧：核函數 $K(x_i, x_j) = \phi(x_i)^T \phi(x_j)$ 直接計算高維空間的內積，避免顯式高維計算的巨大開銷 (維度災難)。

核函數裝甲庫 (The Kernel Armory)


	Linear (線性核)	$\mathbf{x}_i^T \mathbf{x}_j$	特性：<u>計算最快</u>，等同無核函數。 適用：<u>線性可分數據</u>、特徵數 $\gg$ 樣本數的高維資料。
	Polynomial (多項式核)	$(\gamma \mathbf{x}_i^T \mathbf{x}_j + r)^d$	特性：<u>d 控制階數</u>，模型隨 d 變大而複雜。 適用：數據有明確的多項式物理關係。
	RBF / Gaussian (高斯徑向基核)	$\exp(-\gamma \ \mathbf{x}_i - \mathbf{x}_j\ ^2)$	特性：映射到無限維空間，<u>靈活性最高</u>。 適用：<u>最常用的預設選項</u>，適合小樣本、複雜非線性關係。
	Sigmoid	$\tanh(\gamma \mathbf{x}_i^T \mathbf{x}_j + r)$	特性：類似<u>神經網路激活函數</u>。 適用：實際應用較少。

RBF 核與 Gamma (γ) 參數：影響半徑的調控

$\gamma = 1 / (2\sigma^2)$ 。決定單一樣本對決策邊界的影響範圍。




High γ (數值大)



- 影響範圍小，樣本影響力僅限於局部。
- 決策邊界複雜崎嶇。
- 風險：易過擬合。




Low γ (數值小)




- 影響範圍大，單一樣本影響力廣。
- 決策邊界平滑。
- 風險：可能欠擬合。

實務決策：核函數選擇診斷樹



模型綜合調控：SVC 調校三要素



尋找最佳模型，本質上是在這三個幾何維度中尋找泛化能力的平衡點。

實務建置：sklearn 操作員控制面板

PRACTICAL IMPLEMENTATION: sklearn OPERATOR CONTROL PANEL

初始化代碼 (Initialization)

```
from sklearn.svm import SVC  
model = SVC(kernel='rbf', C=1.0, gamma='scale')
```

MODEL INSTANTIATION:
Default Configuration


核心參數盤 (Core Dials)

- **kernel**: 'linear', 'poly', 'rbf' (預設), 'sigmoid' — [SVM Type Selection]
- **C**: 預設 1.0。誤分類懲罰強度。 — [Error Penalty]
- **gamma**: 預設 'scale' ($1 / (n_features \times Var(X))$)。 — [Influence Reach]



進階控制開關 (Advanced Switches)

- **probabiLity**: [預設 False] 啟用後可使用 `predict_proba()`，採 5-fold CV 進行 Platt Scaling 校準，增加訓練時間。 — [Calibrated Probabilities]
- **class_weight**: [預設 None] 處理不平衡數據。可設為 'balanced' 依頻率反比自動調整權重，或自訂字典 {0: 1, 1: 3}。 — [Imbalance Handling]



藍圖結案：SVC 的系統特性與適用場景

Specification Review



系統優勢

- **強大非線性能力**：RBF 核能逼近任意複雜邊界。
- **高維表現優異**：在特徵數大於樣本數時依然穩健。
- **抗噪能力強**：僅由支持向量決定邊界，對非邊界異常值不敏感。
- **全局最優解**：凸優化問題，理論基礎完善，不陷入局部最佳。



工程限制與適用場景

- **計算成本高**：訓練時間複雜度達 $O(n^2) \sim O(n^3)$ ，不適合超大數據集 ($>10,000$)。
- **參數高度敏感**：極度依賴 C 與 gamma 的網格搜索 (Grid Search) 調校。
- **特徵尺度敏感**：必須 **進行資料標準化** (Standardization)。
- **適用建議**：首選於「**中小型樣本、具複雜非線性特徵、要求高準確率**」的分類任務。