


Unit 15: 深度神經網路 (DNN) 與多層感知機 (MLP)


建構化工數據的非線性大腦



為什麼我們需要「深度」？

超越線性回歸，捕捉化工系統的複雜交互作用


傳統線性模型 (Linear Regression)



限制：僅能處理簡單線性關係

✚ 化工系統特性通常具高度非線性與多變數交互作用

深度神經網路 (DNN)



優勢：通用函數逼近器 (Universal Function Approximator)

🧠 自動學習特徵組合


應用場景 (Use Cases)



反應器產率預測




設備故障診斷



虛擬量測 (Soft Sensor)

神經元 (Neuron)：系統的最小運算單元

想像它是一個微型反應器控制器




核心概念：訓練過程即是調整 w (權重) 與 b (偏差)，使預測值接近真實值。


激活函數 (Activation Functions)：非線性的來源

神經網路的「閥門」與「開關」


ReLU (Rectified Linear Unit)




Sigmoid



Softmax



Softmax




Linear



決策指南：隱藏層 → ReLU | 分類輸出 → Sigmoid/Softmax | 回歸輸出 → Linear

系統架構：漏斗型設計 (Funnel Architecture)

資訊瓶頸理論 (Information Bottleneck) —— 去蕪存菁




Rules of Thumb

- 幾何金字塔規則: 節點數建議為 2 的次方 (256, 128, 64)
- Sweet Spot: 結構化數據通常 3-5 層即為甜蜜點

學習機制：前向傳播與反向傳播

預測 → 誤差量測 → 參數修正




損失函數 (Loss Function)：模型的成績單

根據問題類型選擇正確的誤差量測標準

回歸問題 (Regression)


Predicting continuous values like Temp, Yield

MSE (Mean Squared Error)



敏感於異常值
(Penalizes large errors heavily).

MAE (Mean Absolute Error)



對異常值穩健
(Robust to outliers)

分類問題 (Classification)

Predicting categories like Pass/Fail

Binary Crossentropy


- Usage: 二元分類 (Yes/No)
- Pair with: Sigmoid Activation

Categorical Crossentropy

- Usage: 多類別分類 (Grade A/B/C)
- Pair with: Softmax Activation

建構實作：Keras Sequential API

像堆積木一樣建立神經網路



Python Script


```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense, Dropout

# 1. 定義模型架構
model = Sequential([
    # 隱藏層 1: 256 neurons, ReLU
    Dense(256, activation='relu', input_shape=(20,)),
    Dropout(0.3), # 防止過擬合
    # 隱藏層 2: 128 neurons, ReLU
    Dense(128, activation='relu'),
    # 輸出層: 回歸任務 (Linear)
    Dense(1, activation='linear')
])

# 2. 編譯模型
model.compile(optimizer='adam', loss='mse', metrics=['mae'])
```


訓練診斷與策略 (Diagnostics & Strategy)

監控 Loss Curve 以防止過擬合



策略：

使用 **EarlyStopping** callback 監控 Validation Loss，一旦不再改善即停止訓練，並保留最佳權重。

指標 (Metrics)：

MAE (直觀誤差)， R^2 (解釋變異)

決策框架：何時該使用 DNN？

選擇正確的工具解決問題

DNN 適用條件 (Success Criteria)



非線性關係
(High Non-linearity)
- e.g., Kinetics



複雜交互作用
(Complex Interactions)



數據量充足
(Data > 1000 samples)



難以特徵工程
(Hard to Feature Engineer)


典型化工應用 (Typical Applications)



軟測器
(Soft Sensor)



異常檢測
(Anomaly Detection)



預測控制
(Predictive Control)



配方優化
(Formulation)

實例 1：蒸餾塔軟測器 (Distillation Soft Sensor)

預測乙醇濃度 (Ethanol Concentration)

- **Problem:**


即時量測產品組成困難且昂貴。

- **Solution:**

利用 DNN 建立軟測器，輸入 T, P, F 預測濃度。

- **Results:**


DNN MAE 較線性模型降低 ~50%。



實例 2：燃氣渦輪排放預測 (Fuel Gas Emission)

預測氮氧化物 (NOx) —— 應對環保法規


- **Problem:** NOx formation (Zeldovich mechanism) is highly non-linear.
- **Inputs:** TIT (Turbine Inlet Temp), CDP (Compressor Pressure), Humidity.
- **Insight:** DNN 透過 ReLU 層成功捕捉燃燒的非線性物理機制。



實例 3：礦業浮選過程 (Mining Flotation)


矽石濃度預測 —— 時間滯後 (Time Lag) 的重要性

- Discovery: 最重要的特徵不是當前進料，而是 **Lag 6 (1小時前)** 的進料數據。
- Feature Importance: Amina Flow (捕收劑) is critical.
- Lesson: 結合領域知識 (Domain Knowledge) 處理時間序列是成功的關鍵。
- Metric: DNN ($R^2=0.83$) >> Random Forest ($R^2=0.59$).




實例 4：紅酒品質預測 (Red Wine Quality)

從理化性質預測感官評分




Feature Importance Chart



- Flexibility: 可作為回歸 (Score 0-10) 或分類 (Low/Med/High) 問題。
- Insight: DNN 客觀量化了主觀的品質感受。

總結與下一步 (Key Takeaways)

您的數位工具箱已備妥



“DNN 不是黑魔法，而是用數學精確描述的函數逼近器。”

→ Next Step: 開啟 Jupyter Notebook (`Unit15\_DNN\_MLP\_Overview.ipynb`) 開始實作。