


Unit 16: 卷積神經網路 (CNN) 概述

數位化工廠的視覺皮層 (The Visual Cortex of the Digital Chemical Plant)




Noto Sans TC

Roboto Mono


核心任務：理解卷積原理、掌握架構演進、實踐工業檢測
適用場景：晶體分析、缺陷檢測、製程監控

為什麼化工人需要「視覺」能力？(The Data Problem in ChemE)




微觀結構分析
(Microstructure)

晶體形態與粒徑分布




表面缺陷檢測
(Surface Defects)

產品裂紋、雜質與劃痕



製程視覺監控
(Process Monitoring)

熱成像分析與異常狀態




光譜影像分析
(Spectral Imaging)

空間與成分的聯合分佈



傳統感測器只能提供單點數據（純量），而影像數據包含豐富的 **空間結構 (Spatial Structure)** 與 **局部特徵 (Local Patterns)**。

傳統 DNN 的困境：參數爆炸與空間斷裂




假設輸入一張小圖，若第一層有 1024 個神經元：

參數量 = $150,528 \times 1,024 + 1,024$

≈ 1.54 億個參數  **記憶體崩潰、極易過擬合 (Overfitting)**


化工類比 (The Wiring Nightmare)



就像把反應器上的 **每一個** 溫度測點都連接到 **每一個** 控制單元。

 **DNN 將影像展平 (Flatten) 為一維向量，丟失了「像素相鄰」的空間資訊。**

CNN 的解決方案：模擬工業掃描機制



Input Image




局部連接 (Local Connectivity)

神經元只關注局部區域（感受野）。
類比：只檢測反應器局部的溫度梯度。



參數共享 (Parameter Sharing)

同一個濾波器掃描整張影像。
類比：使用 **同一個** 缺陷檢測器掃描整個產品表面。



平移不變性 (Translation Invariance)

無論特徵（如裂紋）出現在左上角還是右下角，都能被識別。

✓ 參數量大幅下降，且保留了 2D 空間結構。


核心引擎：卷積運算 (Convolution)

數學定義 (The Math)

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n)$$

輸入影像 I 與 卷積核 K 的點積總和。

直觀類比 (The Intuition)



卷積核就像一張特製的濾紙：有的濾紙只過濾「**邊緣**」（濃度梯度），有的濾紙只過濾「**紋理**」（表面粗糙度）。CNN 透過訓練自動學習最佳的「濾紙」組合。

降維與壓縮：池化層 (Pooling)

8	4	1	6
3	7	2	5
9	2	4	1
8	6	3	5

Max Pooling (2x2) - Winner Takes All

8	6
9	5




功能：

降維 (Dimensionality Reduction) 與
特徵不變性 (Feature Invariance)。

化工類比：

區域統計 (Zone Monitoring)。不需要監控每一秒的波動，而是取該區域在一段時間內的「最高溫度」作為安全指標。

標準 CNN 架構流程圖




CNN 是一個端到端 (End-to-End) 的自動特徵工程系統，不需要人工設計特徵提取器。


Noto Sans TC (Primary Dark)

經典架構演進：從 LeNet 到 EfficientNet


經典架構時間軸
(Classic Architecture Timeline)



效能與成本權衡
(Performance vs. Cost Trade-off)




實作工具：Keras 架構堆疊



```
model = Sequential([  
    # 提取特徵 Feature Extraction  
    Conv2D(32, (3, 3), activation='relu',  
           input_shape=(64, 64, 1)),  
    MaxPooling2D(2, 2),  
    Conv2D(64, (3, 3), activation='relu'),  
    MaxPooling2D(2, 2),  
  
    # 分類器 Classifier  
    Flatten(),  
    Dense(128, activation='relu'),  
    Dense(6, activation='softmax') # 6類缺陷  
)
```

模型編譯與訓練策略 (Compilation & Training)

Compilation (Control Parameters)



Callbacks (Safety Interlocks)




EarlyStopping (緊急停機)

當誤差不再下降時停止，防止過擬合。



ModelCheckpoint (數據記錄)

自動保存表現最好的模型權重。



ReduceLROnPlateau (精細調節)

學習停滯時，降低學習率。


工業實戰 Case 1：鋼材表面缺陷檢測 (NEU-DET)




Craziing (龜裂)
Roboto Mono



Inclusion (雜質)
Roboto Mono




Patches (斑塊)
Roboto Mono



Pitted (麻點)
Roboto Mono

Accuracy Comparison



Key Takeaway


- ⚠ Random Forest 失敗原因：扁平化導致空間特徵丟失，嚴重混淆雜質與麻點。
- ✓ CNN 成功關鍵：成功捕捉紋理與局部形狀特徵。

CNN Confusion Matrix (NEU-DET)

		Predicted Class					
		Craziing	Inclusion	Patches	Pitted	Rolled-in Scale	Scratches
True Class	Craziing	200	2	5	3	1	0
	Inclusion	1	185	6	2	5	1
	Patches	2	3	190	6	5	1
	Pitted	0	3	2	195	2	1
	Rolled-in Scale	0	1	1	3	205	1
	Scratches	0	0	0	1	2	180
		True Class					

處理更復雜的挑戰：醫學影像與手寫識別

Case 2：結直腸癌組織切片 (Colorectal Histology)



H&E Stain

- 挑戰：組織結構差異細微，誤診成本極高。需關注混淆矩陣的 **Recall** (召回率)，確保無漏判腫瘤。



MNIST

Roboto Mono



Cancer

Roboto Mono

CNN 的卷積核能自動適應從簡單線條 (MNIST) 到複雜生物紋理 (Cancer) 的各種任務。


Case 3：中文手寫數字 (Chinese MNIST)




- 挑戰：15 類別，筆畫複雜度差異巨大 (一 vs. 億)。CNN 仍能達到 **~98%** 準確率。

進階策略：遷移學習 (Transfer Learning)

站在巨人的肩膀上



從模型到產線：部署與決策



ROI Analysis

人工檢測成本 vs. 自動化系統成本 -> 約 1.5 個月回本。

總結：數位化工程師的 CNN 工具箱



“CNN 不是魔法，它是為空間數據量身打造的高效能過濾系統。”