


Unit 17: 循環神經網路 (RNN) 與序列建模

化工製程動態系統的數位孿生核心



Project Stamp	Project Stamp
	課程：AI在化工上之應用
	講師：莊囍楨 助理教授
	製作：智慧程序系統工程實驗室
	日期：2026-01-28

為什麼 DNN 在時間序列任務中失效？

DNN (前饋神經網路)




無視時間順序 (No **Temporal** Context)

DNN 將每個數據點視為獨立樣本
(Independently Identically Distributed)。

ChemE Analogy: 僅分析單一時刻的穩態操作點，無法預測反應趨勢。

RNN (循環神經網路)




具備記憶機制 (Memory Mechanism)

引入**循環連接** (Recurrent Connection)，
隱藏狀態 (**Hidden State**) 在時間步間傳遞。

ChemE Analogy: 如同動態模擬，當前狀態取決於過去的累積 (Accumulation)。

化工數據（溫度、壓力趨勢、批次歷程）本質上是具有時間依賴性的序列數據。


RNN 的運作原理：數位化的 CSTR 反應器



$$\mathbf{h}_t = \tanh(\mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{W}_{xh}\mathbf{x}_t + \mathbf{b}_h)$$

Key Insight: 隱藏狀態 h_t 是一個「滾動總結 (Rolling Summary)」，濃縮了從 $t = 0$ 到當前的所有歷史資訊。

系統瓶頸：梯度消失問題 (The Vanishing Gradient Problem)



📖 BPTT (Backpropagation Through Time)：梯度需連乘多次 W_{hh} 。


- Condition: 若權重特徵值 < 1 且使用 $\tanh$ (導數 < 1)。
- Result: $\lambda^T \rightarrow 0$ (當 T 很大)。早期資訊被「遺忘」，網路無法學習長期依賴。



就像訊號在長管道傳輸中衰減，RNN 難以關聯批次反應初期操作對最終產品品質的影響。

解決方案：LSTM（長短期記憶網路）

配備精密控制閥的進階製程單元




關鍵優勢：梯度可以通過 Cell State 的『直通路徑』流動，有效避免梯度消失。

適用場景：適用於超長序列 (>50步) 與複雜的間延遲任務。

效率優化：GRU（門控循環單元）

精簡設計的高效能反應器




LSTM (3 Valves)

Efficiency Stats

- 參數量：比 LSTM 少約 25%
- 運算速度：更快的訓練與推論速度

重置門 (Reset Gate)

決定忽略多少過去資訊。



GRU (2 Valves)

更新門 (Update Gate)

同時扮演遺忘與輸入的角色 (Mixing Ratio)。



Decision Heuristic

在化工應用中，GRU 通常是首選 (Default Choice)，除非數據量極大或任務極其複雜。

架構規格比較表 (Architecture Specification Sheet)


特性	SimpleRNN	LSTM	GRU
構造複雜度 (Structural)	低 (Low)	高 (High)	中 (Medium)
參數量 (Params)	1x	4x	3x
長期記憶 (Long-Term Memory)	差 (Poor)	優秀 (Excellent)	良好 (Good)
收斂速度 (Convergence Speed)	中等 (Medium)	慢 (Slow)	最快 (Fastest)
化工應用場景	極短序列、教學演示	設備RUL預測、複雜多步控制	批次品質預測、異常檢測 (首選)




Decision Heuristic: GRU offers the best balance of performance and efficiency for most industrial time-series tasks.

在化工應用中，GRU通常是首選，提供最佳的性能與效率平衡。

數據工程：建構 3D 輸入張量




1. 滑動視窗 (Sliding Window)



用於連續製程數據截取

2. 批次分割 (Batch Segmentation)



用於批次反應數據整理

Keras 實作：數位控制邏輯

Digital Terminal

```
from tensorflow.keras import layers, models
```

```
model = models.Sequential([  
    # Input: (None, 30, 10) - 30 timesteps, 10 features  
    layers.GRU(units=64, return_sequences=True, input_shape=(30, 10)),  
    layers.Dropout(0.2), # Prevent Overfitting  
    layers.LSTM(units=32, return_sequences=False),  
    layers.Dense(1)      # Output: Prediction  
])
```



隱藏狀態 (ht) 的維度



定義時間步與特徵數




防止過擬合的機制




關鍵參數詳解：return_sequences

A. return_sequences=True



堆疊層 (Stacking) 或序列標註。保留完整時間歷程。

B. return_sequences=False




分類或回歸。只取最後一刻的『總結』狀態。

Rule of Thumb: 堆疊 RNN 層時，前層設為 **True**，最後一層設為 **False**（通常情況）。

訓練協定：安全連鎖系統 (Safety Interlocks)

防止梯度爆炸與訓練發散


1 梯度裁剪 (Gradient Clipping)



```
optimizer = Adam(learning_rate=0.001, clipnorm=1.0)
```

當 Whh 特徵值 >1 ，梯度會指數級增長。裁剪將其限制在安全範圍。

2 學習率策略 (Solver)



推薦使用 **Adam 優化器** (自適應學習率)。

3 Callbacks



- **EarlyStopping:** 監控驗證損失，防止過擬合。




- **ReduceLROnPlateau:** 遇瓶頸時自動降低學習率。

最佳實踐檢查表 (Best Practices Checklist)



實驗設計：三種架構的性能對決


SimpleRNN vs. LSTM vs. GRU



Data Highlight: 任務為多對一回歸 (Many-to-One Regression)，預測反應器最終指標。

實驗結果分析 (Experimental Results)

Line Chart




MAE (Lower is Better)



Conclusion Box

- LSTM：精度最高，適合對誤差容忍度低的任務。
- GRU：效率之王，參數量少 24%，收斂快 1.8 倍。
- SimpleRNN：僅具教學意義，實務不推薦。

總結：化工領域的應用場景導航



軟感測器 (Soft Sensors)

難測變數估計。
Model: GRU/LSTM (多對一)



預測性維護 (Predictive Maintenance)

設備 RUL 預測。
Model: LSTM
(捕捉長期退化趨勢)



過程監控 (Process Monitoring)

批次操作異常檢測。
Model: GRU (實時數據流)



動態控制 (Predictive Control)

未來多步狀態預測。
Model: Seq2Seq LSTM

選擇合適的模型架構，構建您的化工數位孿生。